

# Python 3 玩儿转机器学习

讲师：liuyubobobo

版权所有 侵权必究  
liuyubobobo

慕课网《Python3机器学习》

梯度下降法

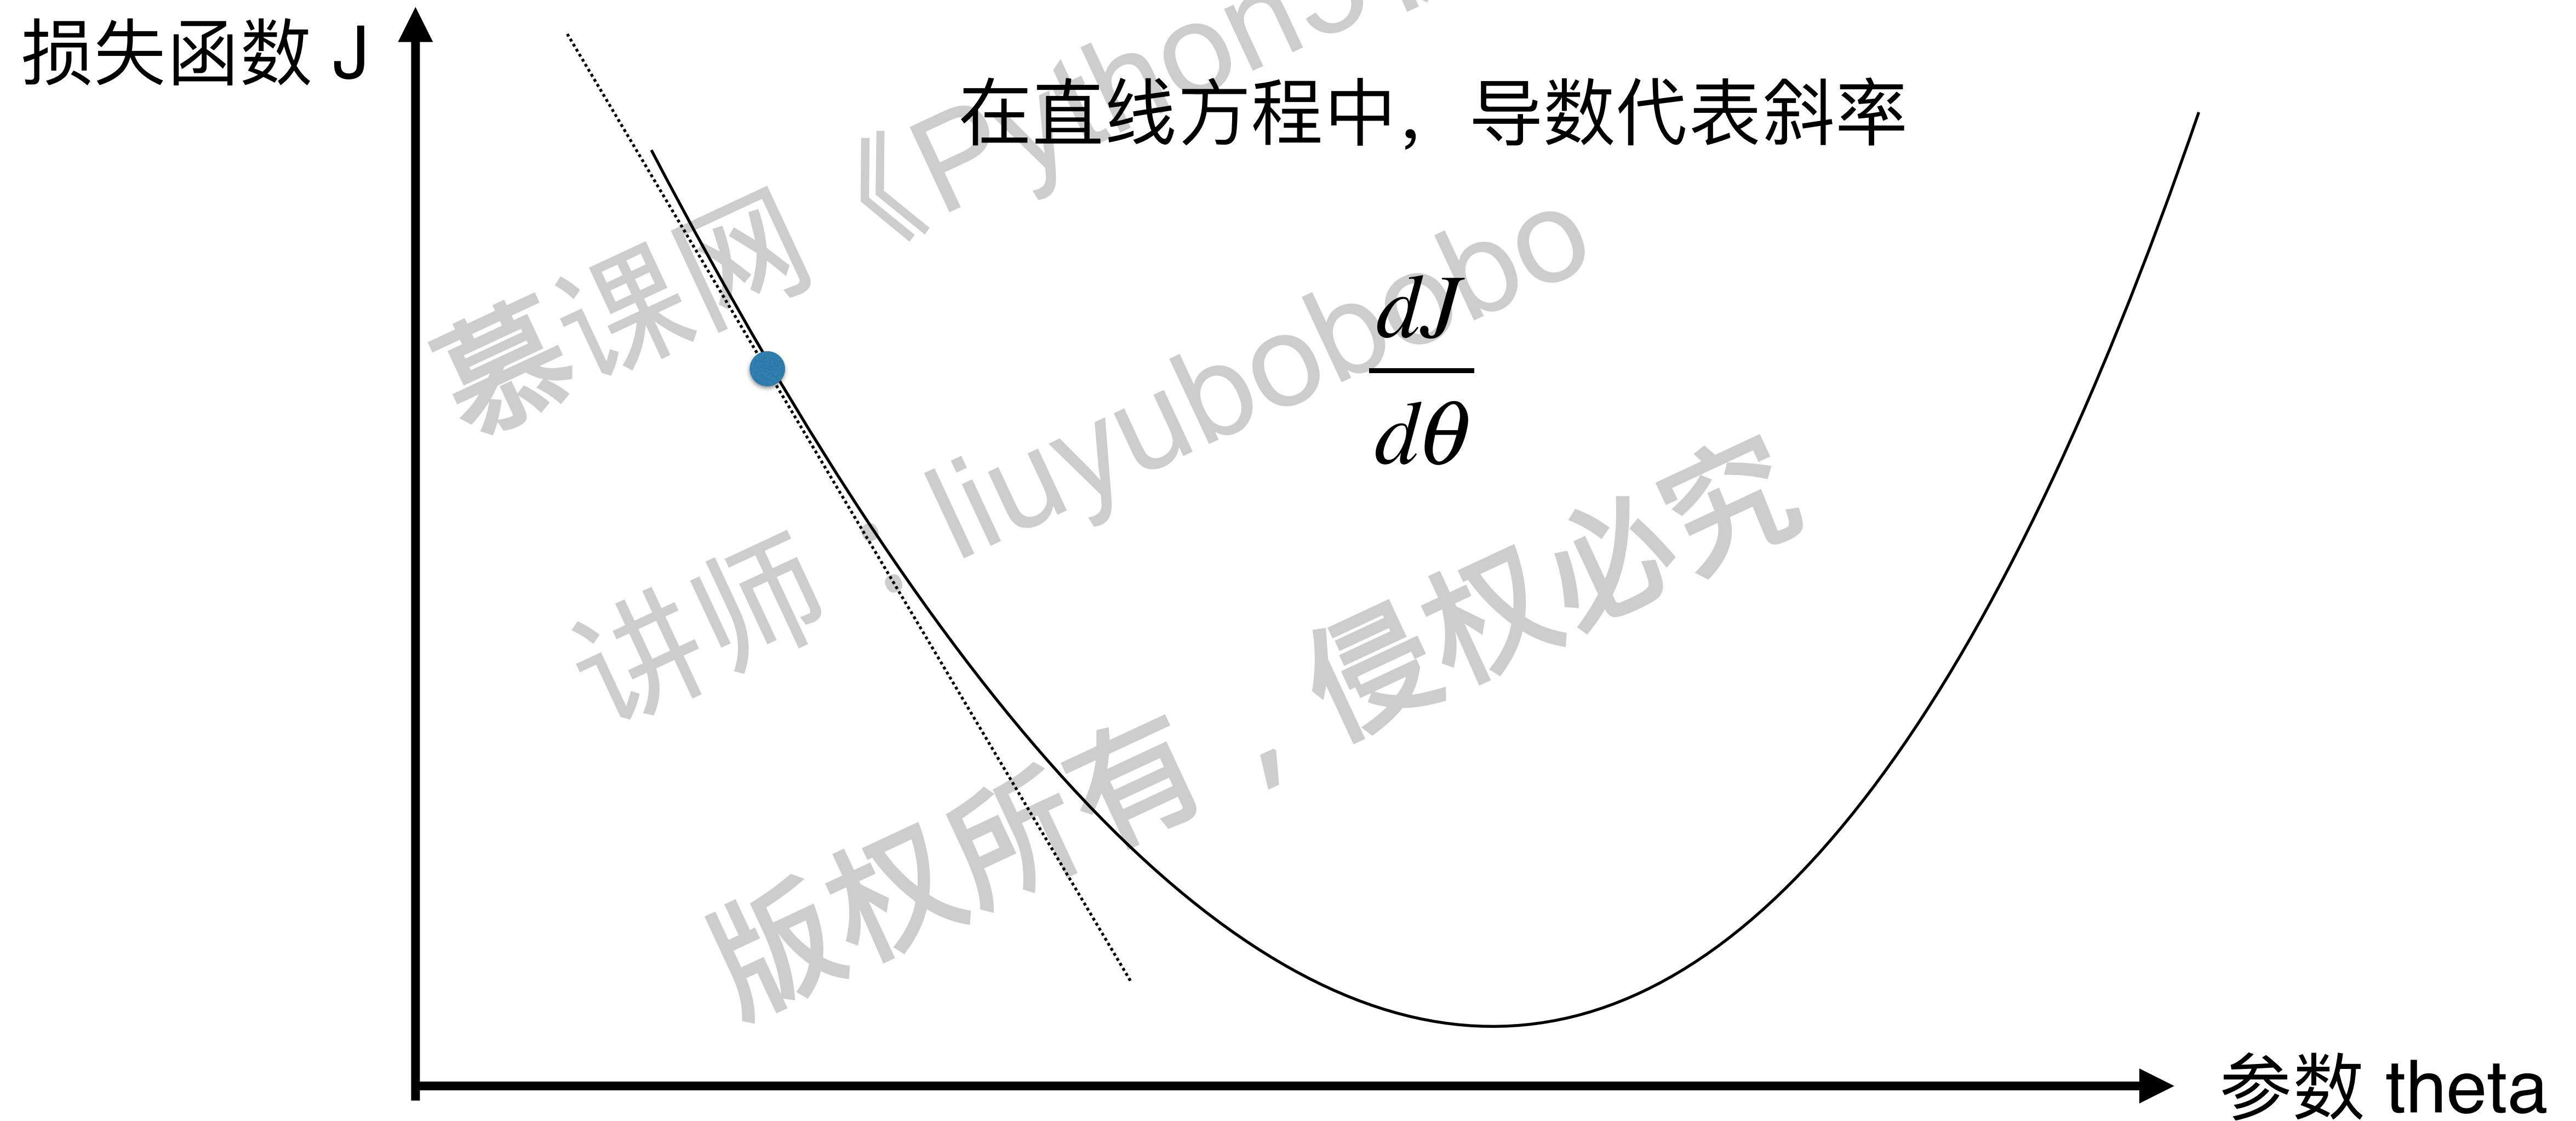
Gradient Descent

讲师: jiuYubobob9  
版权所有, 侵权必究

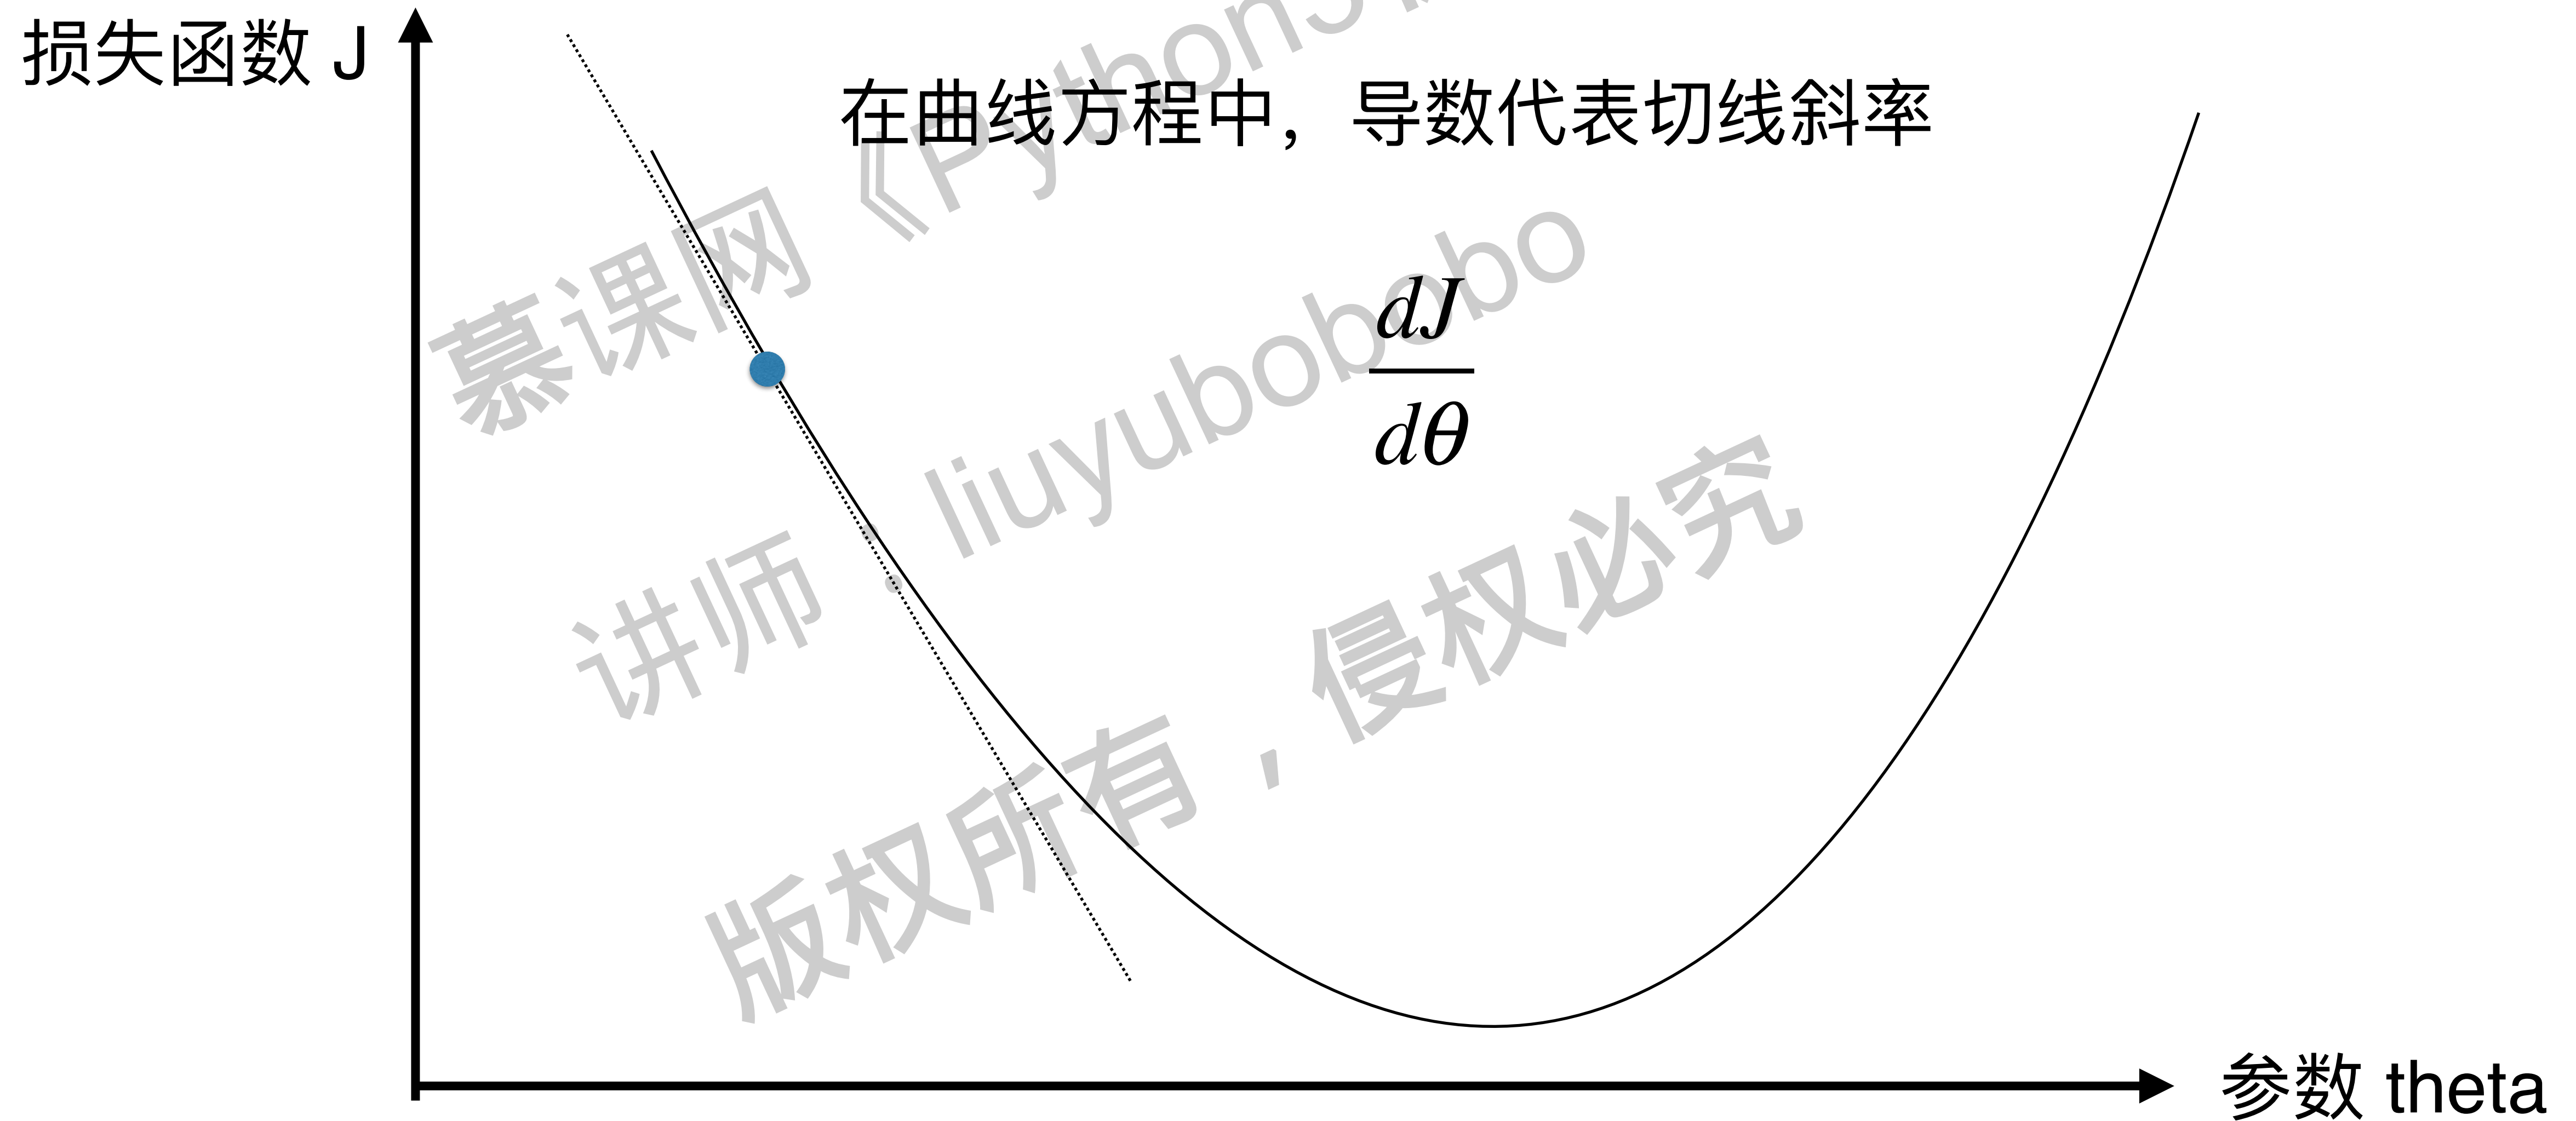
# 梯度下降法

- 不是一个机器学习算法
- 是一种基于搜索的最优化方法
- 作用：最小化一个损失函数
- 梯度上升法：最大化一个效用函数


# 梯度下降法



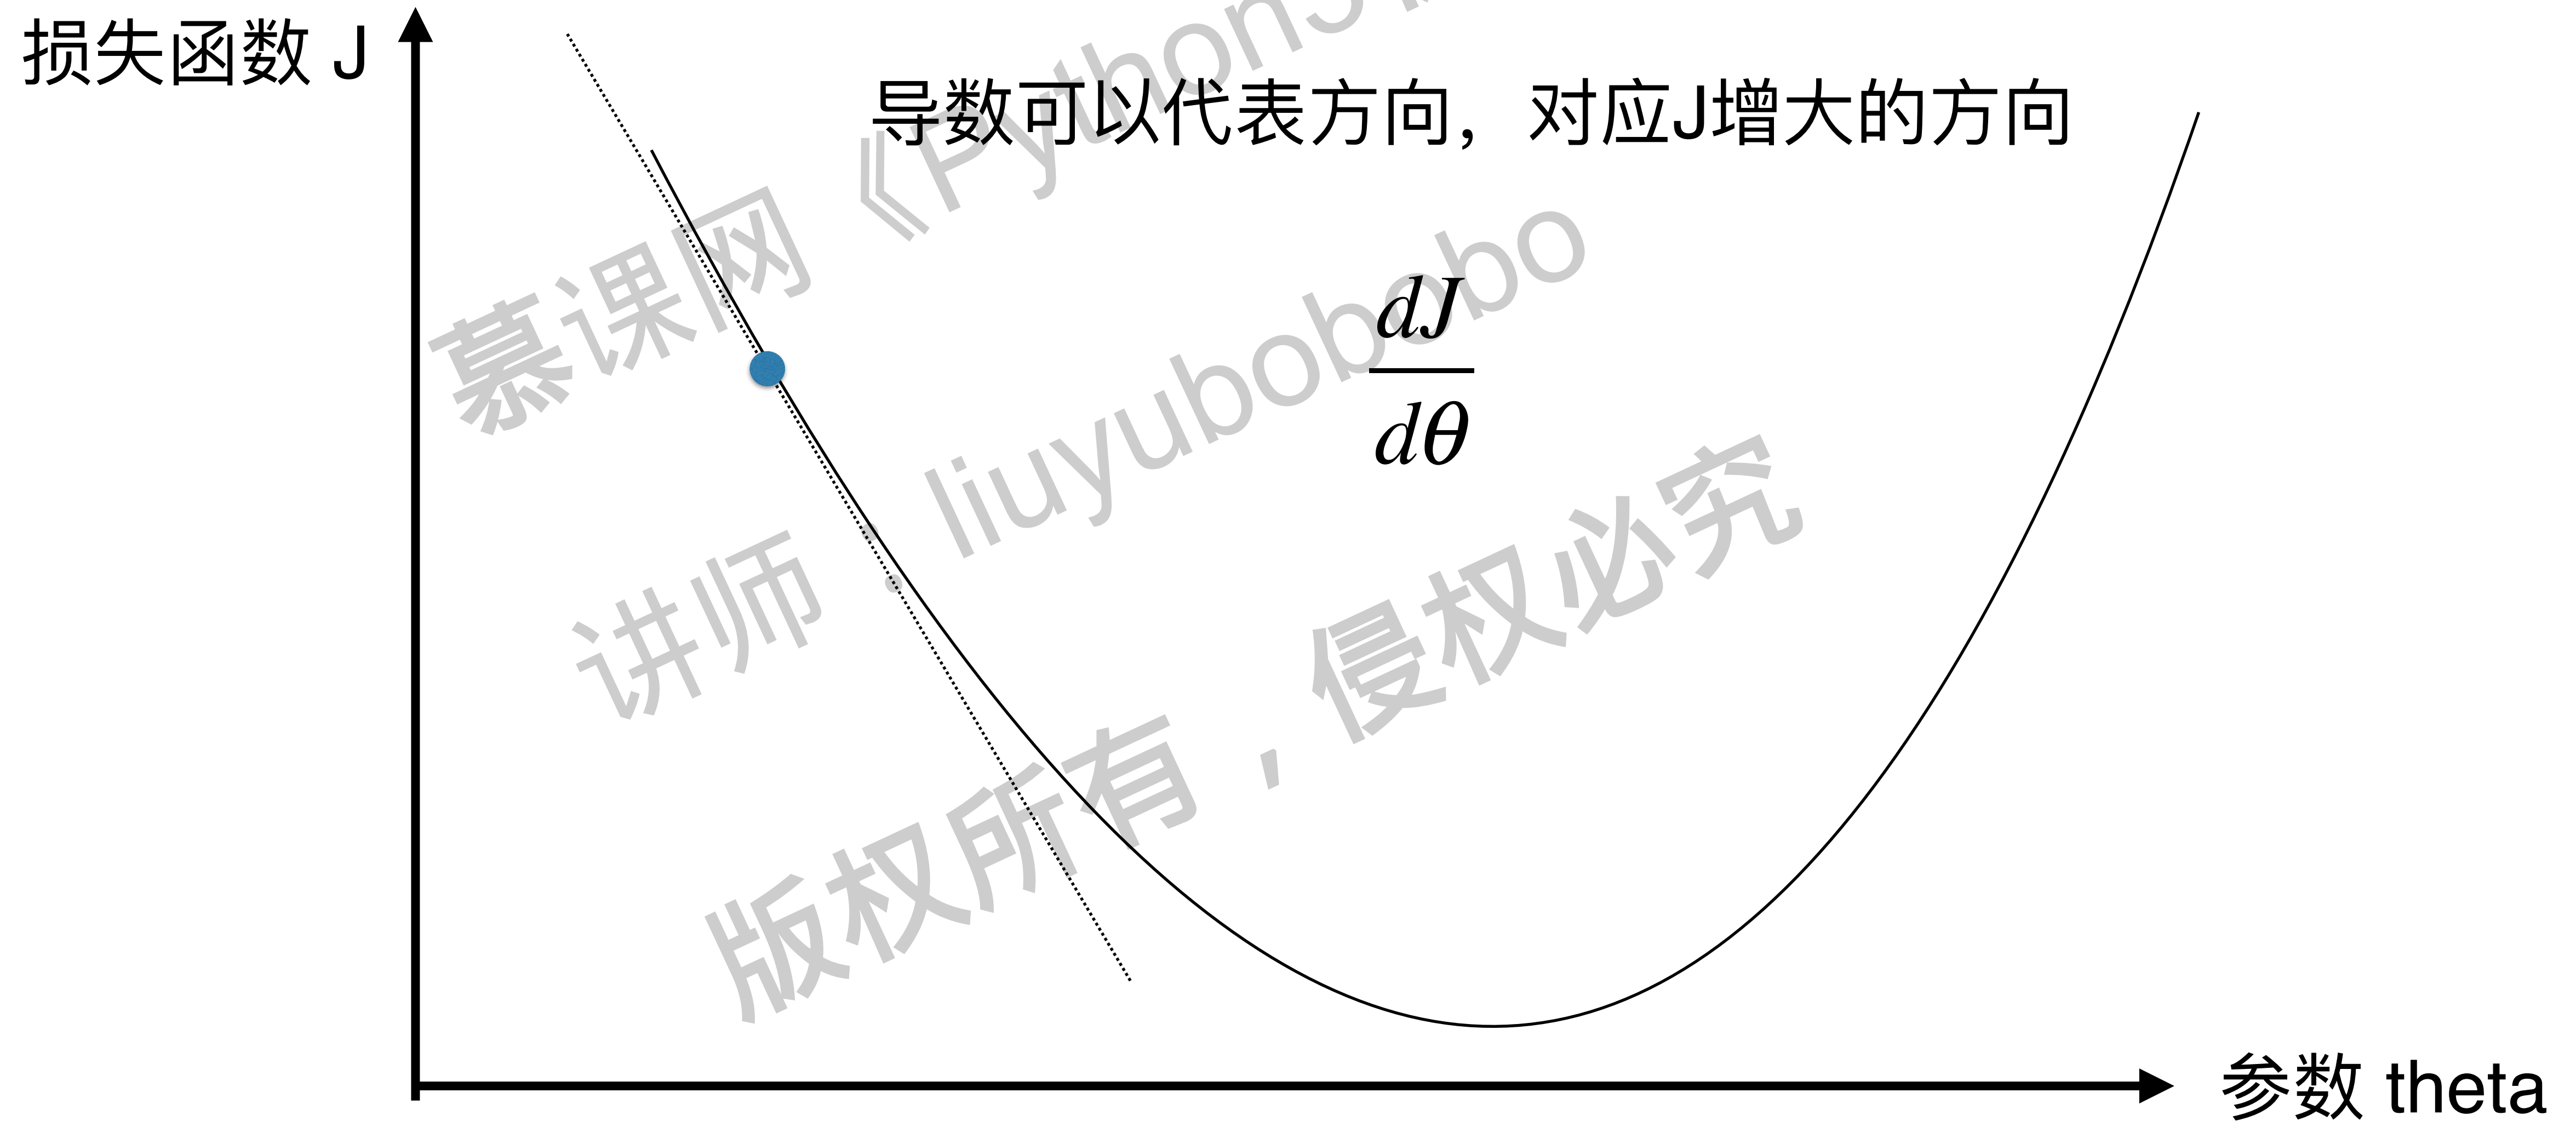
# 梯度下降法



# 梯度下降法




# 梯度下降法






# 梯度下降法






# 梯度下降法




# 梯度下降法



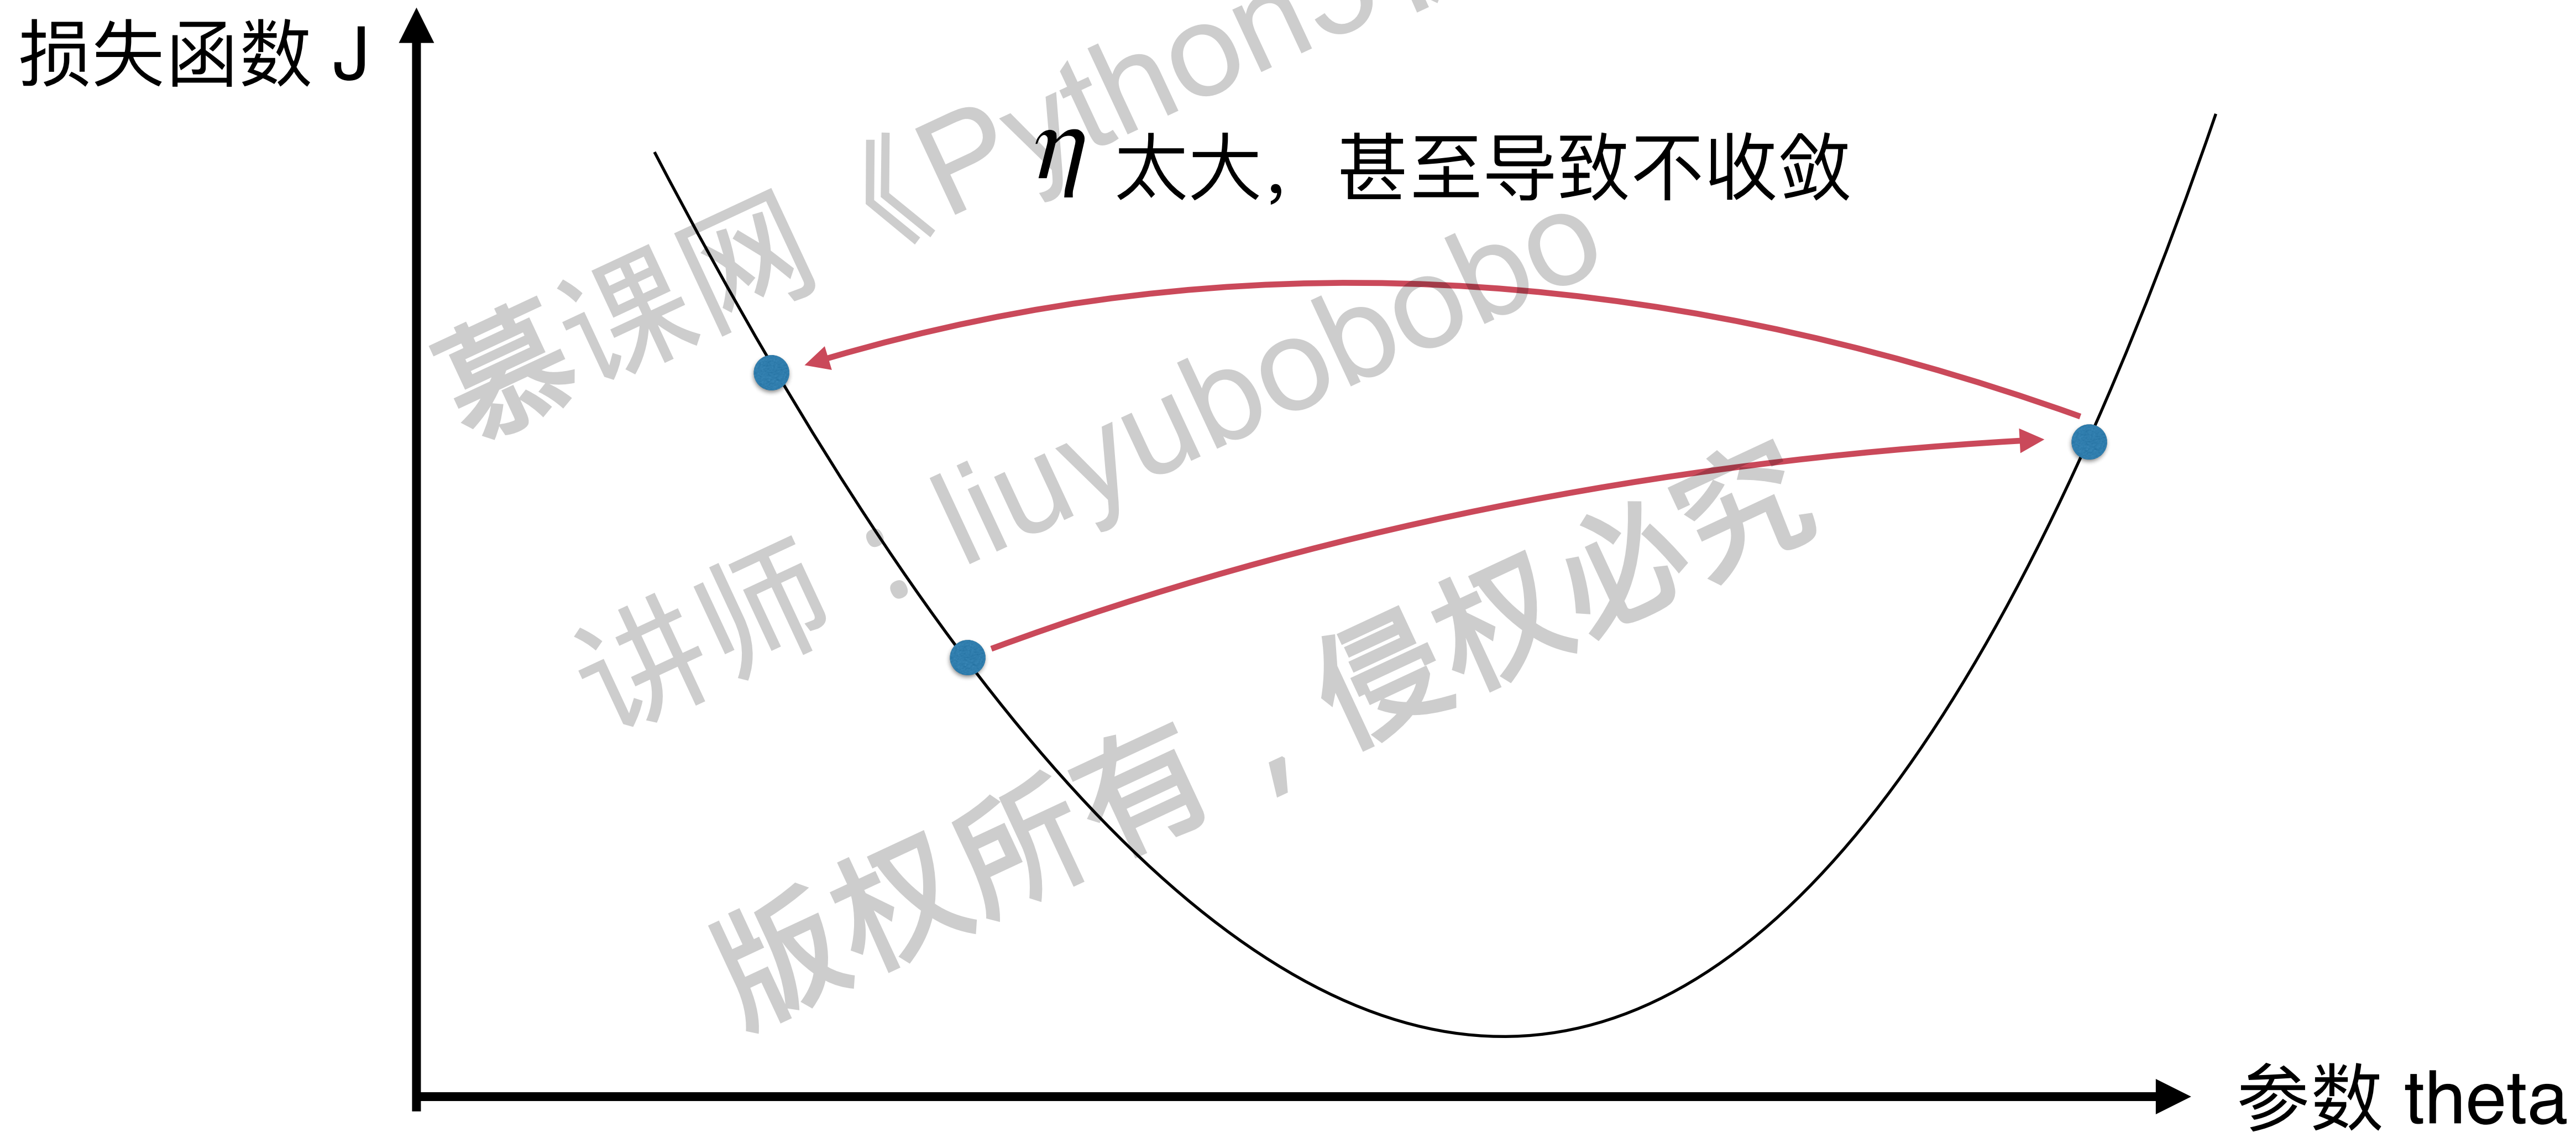
# 梯度下降法

- $\eta$  称为学习率(learning rate)
  - $\eta$  的取值影响获得最优解的速度
  - $\eta$  取值不合适，甚至得不到最优解
  - $\eta$  是梯度下降法的一个超参数

# 梯度下降法




# 梯度下降法



# 梯度下降法

- 并不是所有函数都有唯一的极值点

# 梯度下降法





# 梯度下降法

- 并不是所有函数都有唯一的极值点

解决方案:

- 多次运行, 随机化初始点
- 梯度下降法的初始点也是一个超参数

# 线性回归中使用梯度下降法

目标：使  $\sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)})^2$  尽可能小

线性回归法的损失函数具有唯一的最优解

慕课网《Python3机器学习》

# 模拟梯度下降法

讲师：liuyunbo

版权所有，侵权必究

慕课网《Python3机器学习》

# 实践：模拟梯度下降法

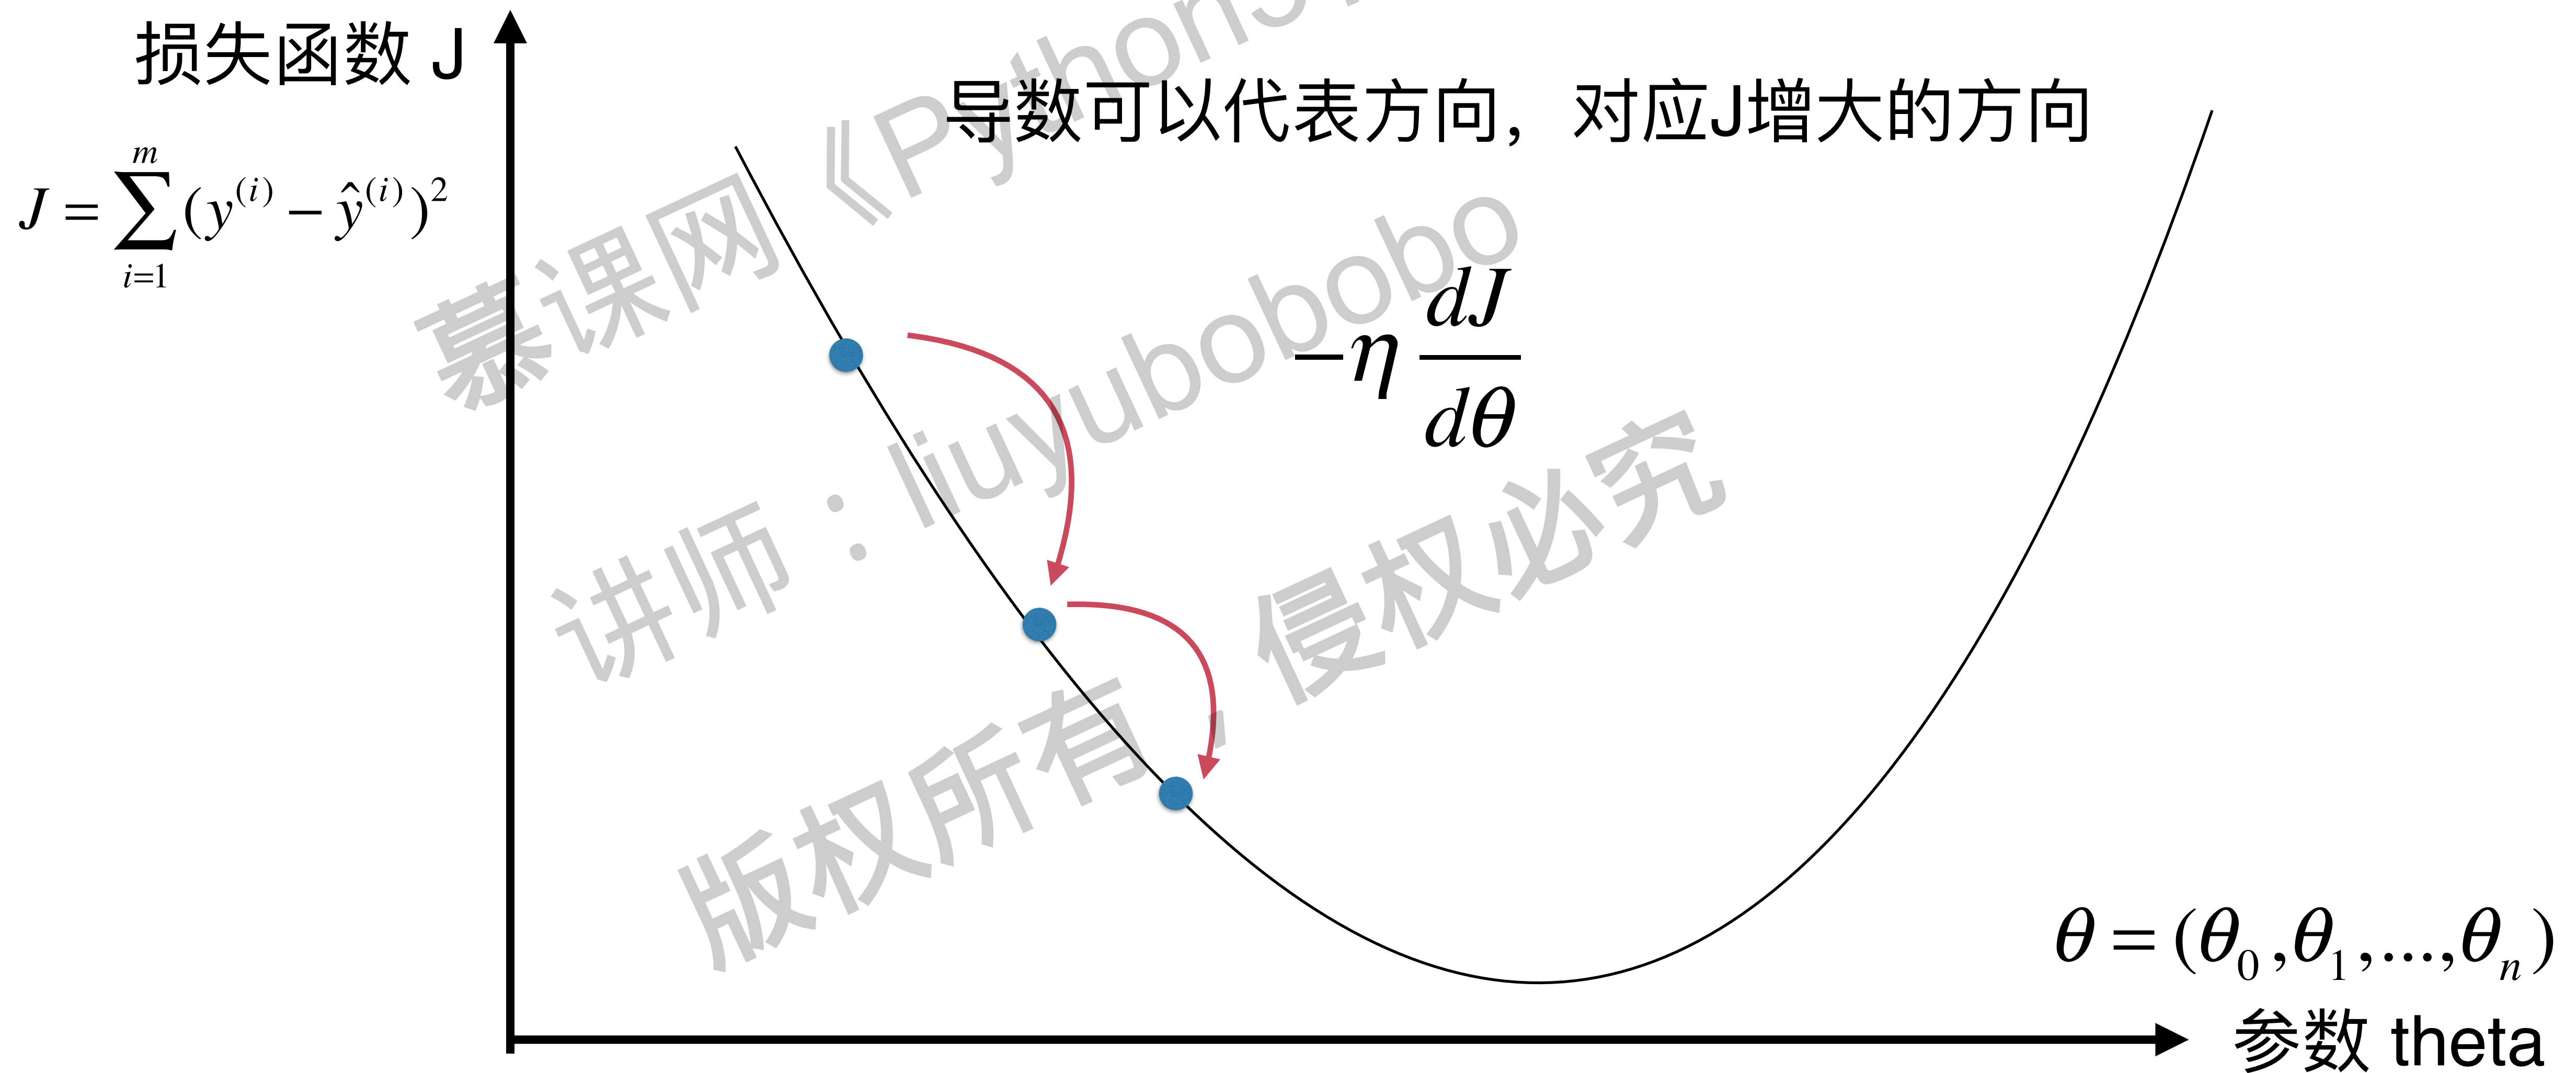
讲师：liuyubobobo

版权所有，侵权必究

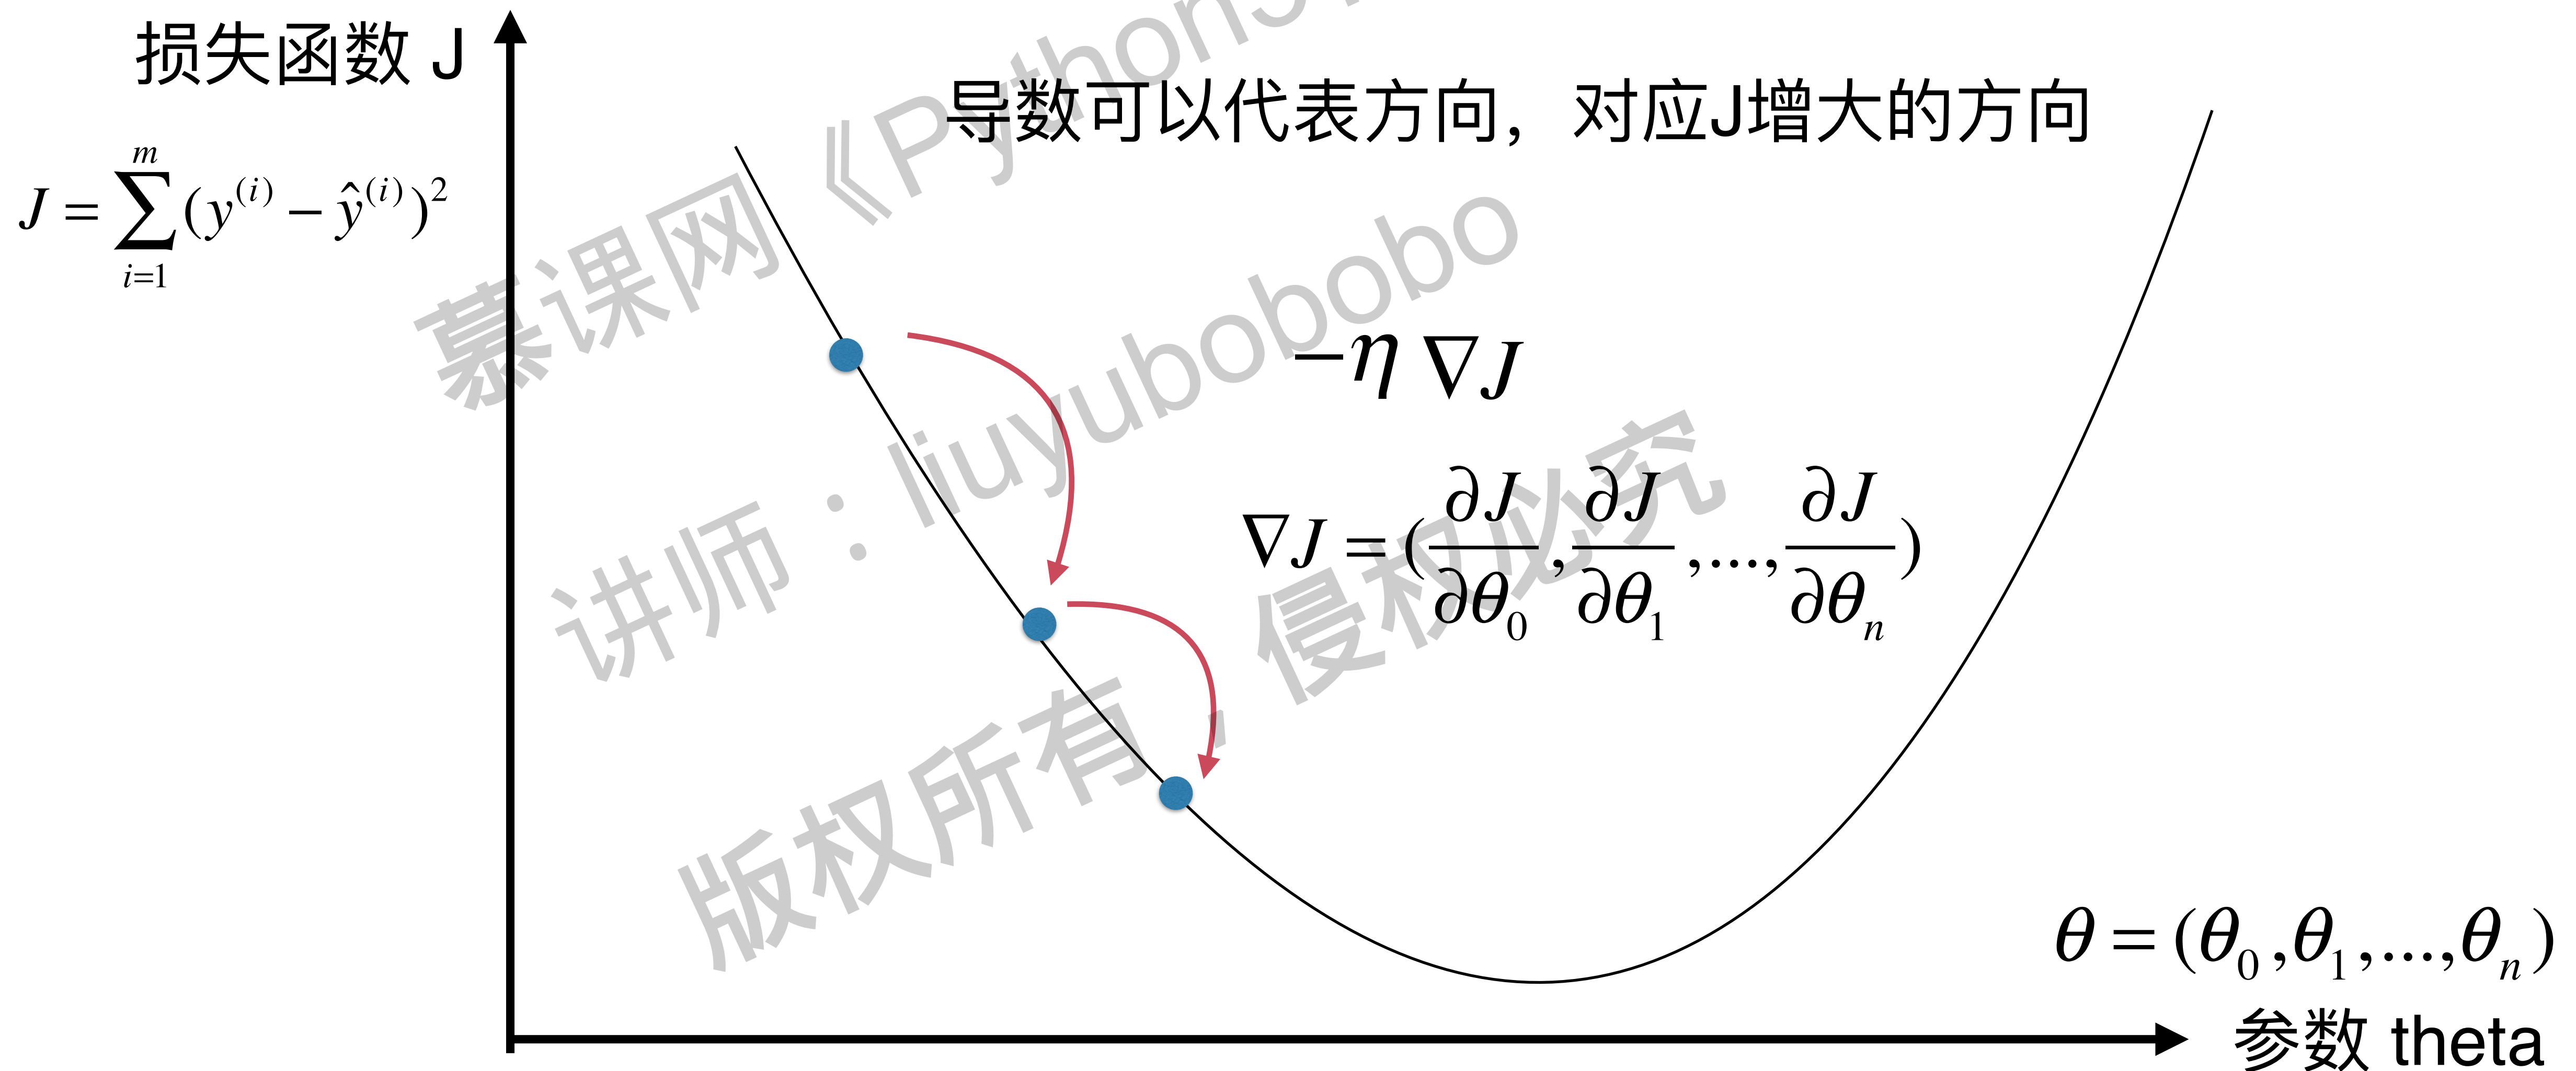
# 多元线性回归中的梯度下降法

讲师：liuyubobobo  
版权所有，侵权必究

# 梯度下降法



# 梯度下降法





# 梯度下降法

损失函数 J

$$J = \sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)})^2$$

梯度代表方向，对应J增大最快的方向

$$-\eta \nabla J$$

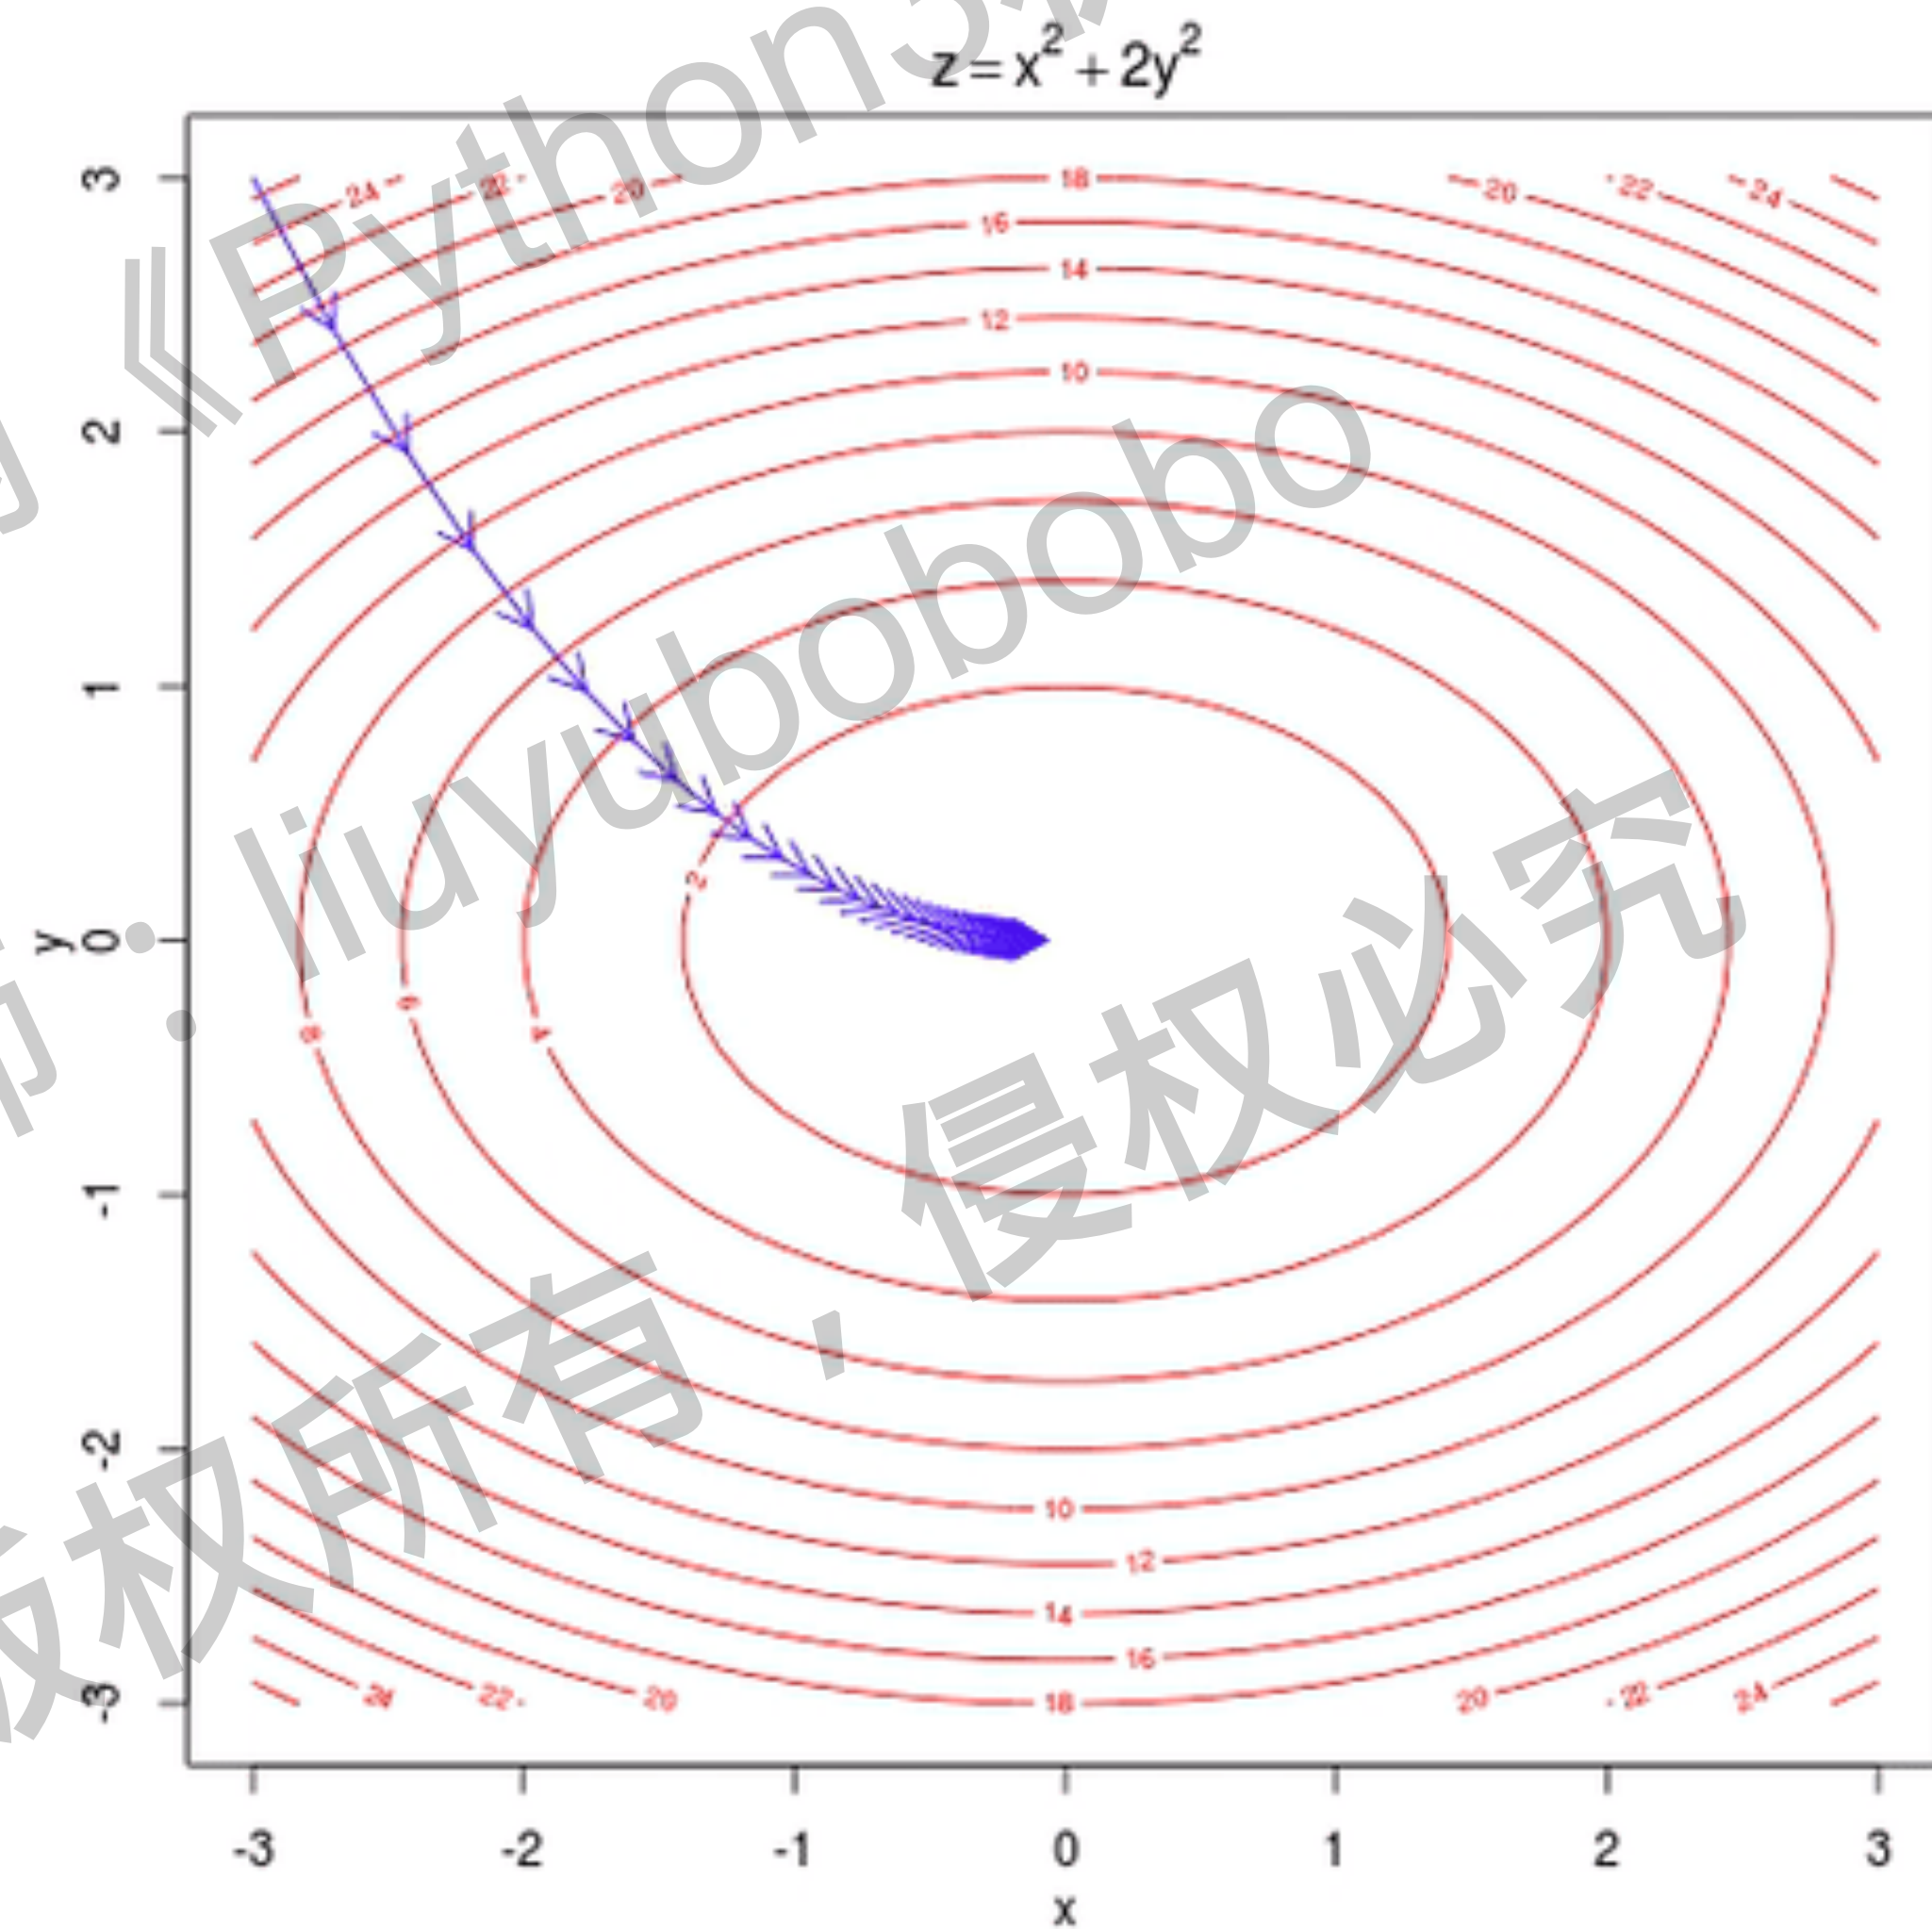
$$\nabla J = \left( \frac{\partial J}{\partial \theta_0}, \frac{\partial J}{\partial \theta_1}, \dots, \frac{\partial J}{\partial \theta_n} \right)$$

$$\theta = (\theta_0, \theta_1, \dots, \theta_n)$$

参数 theta

慕课网《Python3机器学习》  
讲师：liuyubobobo  
版权所有，侵权必究

# 梯度下降法



# 线性回归中使用梯度下降法

目标：使  $\sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)})^2$  尽可能小

$$\hat{y}^{(i)} = \theta_0 + \theta_1 X_1^{(i)} + \theta_2 X_2^{(i)} + \dots + \theta_n X_n^{(i)}$$

目标：使  $\sum_{i=1}^m (y^{(i)} - \theta_0 - \theta_1 X_1^{(i)} - \theta_2 X_2^{(i)} - \dots - \theta_n X_n^{(i)})^2$  尽可能小

# 线性回归中使用梯度下降法

目标：使  $\sum_{i=1}^m (y^{(i)} - \theta_0 - \theta_1 X_1^{(i)} - \theta_2 X_2^{(i)} - \dots - \theta_n X_n^{(i)})^2$  尽可能小

$$\nabla J(\theta) = \begin{pmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \\ \frac{\partial J}{\partial \theta_2} \\ \dots \\ \frac{\partial J}{\partial \theta_n} \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^m 2(y^{(i)} - X_b^{(i)}\theta) \cdot (-1) \\ \sum_{i=1}^m 2(y^{(i)} - X_b^{(i)}\theta) \cdot (-X_1^{(i)}) \\ \sum_{i=1}^m 2(y^{(i)} - X_b^{(i)}\theta) \cdot (-X_2^{(i)}) \\ \dots \\ \sum_{i=1}^m 2(y^{(i)} - X_b^{(i)}\theta) \cdot (-X_n^{(i)}) \end{pmatrix} = 2 \cdot \begin{pmatrix} \sum_{i=1}^m (X_b^{(i)}\theta - y^{(i)}) \\ \sum_{i=1}^m (X_b^{(i)}\theta - y^{(i)}) \cdot X_1^{(i)} \\ \sum_{i=1}^m (X_b^{(i)}\theta - y^{(i)}) \cdot X_2^{(i)} \\ \dots \\ \sum_{i=1}^m (X_b^{(i)}\theta - y^{(i)}) \cdot X_n^{(i)} \end{pmatrix}$$



# 线性回归中使用梯度下降法

目标：使  $\sum_{i=1}^m (y^{(i)} - \theta_0 - \theta_1 X_1^{(i)} - \theta_2 X_2^{(i)} - \dots - \theta_n X_n^{(i)})^2$  尽可能小

$$\nabla J(\theta) = \begin{pmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \\ \frac{\partial J}{\partial \theta_2} \\ \dots \\ \frac{\partial J}{\partial \theta_n} \end{pmatrix} = \frac{2}{m} \cdot \begin{pmatrix} \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_1^{(i)} \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_2^{(i)} \\ \dots \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_n^{(i)} \end{pmatrix}$$

# 线性回归中使用梯度下降法

目标：使  $\frac{1}{m} \sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)})^2$  尽可能小

$$J(\theta) = \text{MSE}(y, \hat{y})$$

有时取：  $J(\theta) = \frac{1}{2m} \sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)})^2$

$$\nabla J(\theta) =$$

$$\begin{pmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \\ \frac{\partial J}{\partial \theta_2} \\ \dots \\ \frac{\partial J}{\partial \theta_n} \end{pmatrix}$$

$$= \frac{2}{m} \cdot$$

$$\begin{pmatrix} \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_1^{(i)} \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_2^{(i)} \\ \dots \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_n^{(i)} \end{pmatrix}$$

# 线性回归中使用梯度下降法

目标：使  $\frac{1}{m} \sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)})^2$  尽可能小

$$J(\theta) = MSE(y, \hat{y})$$

$$\nabla J(\theta)$$

$$= \begin{pmatrix} \frac{\partial J}{\partial \theta_0} \\ \frac{\partial J}{\partial \theta_1} \\ \frac{\partial J}{\partial \theta_2} \\ \dots \\ \frac{\partial J}{\partial \theta_n} \end{pmatrix}$$

$$= \frac{2}{m} \cdot$$

$$\begin{pmatrix} \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_1^{(i)} \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_2^{(i)} \\ \dots \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_n^{(i)} \end{pmatrix}$$



# 实践：线性回归使用梯度下降法训练

慕课网《Python3机器学习》  
讲师：liuyubobobo  
版权所有，侵权必究

# 线性回归中梯度下降法的向量化

讲师：liuyunbo

版权所有，侵权必究

# 线性回归中使用梯度下降法

$$\nabla J(\theta) = \frac{2}{m} \cdot \begin{pmatrix} \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_1^{(i)} \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_2^{(i)} \\ \dots \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_n^{(i)} \end{pmatrix} = \frac{2}{m} \cdot \begin{pmatrix} \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_0^{(i)} \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_1^{(i)} \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_2^{(i)} \\ \dots \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_n^{(i)} \end{pmatrix}$$

# 线性回归中使用梯度下降法

$$\begin{aligned}
 &= \frac{2}{m} \cdot \left( \begin{array}{c} \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_0^{(i)} \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_1^{(i)} \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_2^{(i)} \\ \dots \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_n^{(i)} \end{array} \right) \\
 &\quad \cdot \left( \begin{array}{ccccc} X_0^{(1)} & X_1^{(1)} & X_2^{(1)} & \dots & X_n^{(1)} \\ X_0^{(2)} & X_1^{(2)} & X_2^{(2)} & \dots & X_n^{(2)} \\ X_0^{(3)} & X_1^{(3)} & X_2^{(3)} & \dots & X_n^{(3)} \\ \dots & \dots & \dots & \dots & \dots \\ X_0^{(m)} & X_1^{(m)} & X_2^{(m)} & \dots & X_n^{(m)} \end{array} \right) \\
 &\quad = \frac{2}{m} \cdot (X_b \theta - y)^T \cdot X_b \\
 &\quad = \frac{2}{m} \cdot X_b^T \cdot (X_b \theta - y)
 \end{aligned}$$

# 线性回归中使用梯度下降法

$$\nabla J(\theta) = \frac{2}{m} \cdot \begin{pmatrix} \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_0^{(i)} \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_1^{(i)} \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_2^{(i)} \\ \dots \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_n^{(i)} \end{pmatrix} = \frac{2}{m} \cdot X_b^T \cdot (X_b \theta - y)$$

# 实践：线性回归使用向量化的梯度下降法训练

慕课网《Python3机器学习》


讲师：liuyubobobo

版权所有，侵权必究



# 梯度下降法与数据归一化

使用梯度下降法前，最好进行数据归一化





慕课网《Python3机器学习》

实践：数据归一化后，使用  
梯度下降法训练

讲师：liuyubobobo  
版权所有，侵权必究

慕课网《Python3机器学习》

# 随机梯度下降法

讲师：liuyubobobo

版权所有，侵权必究


# 批量梯度下降法 Batch Gradient Descent

$$\nabla J(\theta) = \frac{2}{m} \cdot \begin{pmatrix} \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_0^{(i)} \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_1^{(i)} \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_2^{(i)} \\ \vdots \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_n^{(i)} \end{pmatrix} = \frac{2}{m} \cdot X_b^T \cdot (X_b \theta - y)$$


# 随机梯度下降法 Stochastic Gradient Descent

$$= \frac{2}{m} \cdot \left( \begin{array}{c} \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_0^{(i)} \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_1^{(i)} \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_2^{(i)} \\ \dots \\ \sum_{i=1}^m (X_b^{(i)} \theta - y^{(i)}) \cdot X_n^{(i)} \end{array} \right) \quad \Bigg| \quad 2 \cdot \left( \begin{array}{c} (X_b^{(i)} \theta - y^{(i)}) \cdot X_0^{(i)} \\ (X_b^{(i)} \theta - y^{(i)}) \cdot X_1^{(i)} \\ (X_b^{(i)} \theta - y^{(i)}) \cdot X_2^{(i)} \\ \dots \\ (X_b^{(i)} \theta - y^{(i)}) \cdot X_n^{(i)} \end{array} \right) = 2 \cdot (X_b^{(i)})^T \cdot (X_b^{(i)} \theta - y^{(i)})$$

# 随机梯度下降法 Stochastic Gradient Descent



# 随机梯度下降法 Stochastic Gradient Descent



$$\eta = \frac{1}{i\_iters}$$



$$\eta = \frac{1}{i\_iters + b}$$



$$\eta = \frac{a}{i\_iters + b}$$



# 随机梯度下降法 Stochastic Gradient Descent

模拟退火的思想

$$\eta = \frac{t_0}{i\_iters + t_1}$$

# 实践：线性回归使用随机梯度下降法训练

慕课网《Python3机器学习》  
讲师：liuyubobobo

版权所有，侵权必究

实践：封装我们自己的随机梯度下降法

# scikit-learn中的随机梯度下降法

慕课网《Python3机器学习》

讲师：liuyubobobo

版权所有，侵权必究


慕课网《Python3机器学习》

## 更多有关梯度下降法的讨论

讲师：liuyubobobo


版权所有，侵权必究

# 关于梯度的调试





# 关于梯度的调试



$$\frac{dJ}{d\theta} = \frac{J(\theta + \epsilon) - J(\theta - \epsilon)}{2\epsilon}$$

# 关于梯度的调试

$$\theta = (\theta_0, \theta_1, \theta_2, \dots, \theta_n)$$

$$\theta_0^+ = (\theta_0 + \varepsilon, \theta_1, \theta_2, \dots, \theta_n)$$

$$\theta_0^- = (\theta_0 - \varepsilon, \theta_1, \theta_2, \dots, \theta_n)$$

$$\frac{\partial J}{\partial \theta} = \left( \frac{\partial J}{\partial \theta_0}, \frac{\partial J}{\partial \theta_1}, \frac{\partial J}{\partial \theta_2}, \dots, \frac{\partial J}{\partial \theta_n} \right)$$

$$\frac{\partial J}{\partial \theta_0} = \frac{J(\theta_0^+) - J(\theta_0^-)}{2\varepsilon}$$

# 关于梯度的调试

$$\theta = (\theta_0, \theta_1, \theta_2, \dots, \theta_n)$$

$$\theta_1^+ = (\theta_0, \theta_1 + \varepsilon, \theta_2, \dots, \theta_n)$$

$$\theta_1^- = (\theta_0, \theta_1 - \varepsilon, \theta_2, \dots, \theta_n)$$

$$\frac{\partial J}{\partial \theta} = \left( \frac{\partial J}{\partial \theta_0}, \frac{\partial J}{\partial \theta_1}, \frac{\partial J}{\partial \theta_2}, \dots, \frac{\partial J}{\partial \theta_n} \right)$$

$$\frac{\partial J}{\partial \theta_1} = \frac{J(\theta_1^+) - J(\theta_1^-)}{2\varepsilon}$$

慕课网《Python3机器学习》

## 实践：关于梯度的调试

讲师：liuyubobobo

版权所有，侵权必究

# 梯度下降法

- 批量梯度下降法 Batch Gradient Descent
- 随机梯度下降法 Stochastic Gradient Descent
- 小批量梯度下降法 Mini-Batch Gradient Descent

# 随机

- 跳出局部最优解
- 更快的运行速度
- 机器学习领域很多算法都要使用随机的特点：  
随机搜索； 随机森林




# 梯度上升法

目标函数f

梯度可以代表方向，对应J增大的最快方向

$$-\eta \frac{dJ}{d\theta}$$

参数 theta




# 梯度上升法

目标函数f

梯度可以代表方向，对应J增大的最快方向

$$+\eta \frac{dJ}{d\theta}$$

参数 theta



# 梯度上升法

梯度可以代表方向，对应J增大的最快方向

$$+\eta \frac{dJ}{d\theta}$$

# 梯度下降法

- 不是一个机器学习算法
- 是一种基于搜索的最优化方法
- 作用：最小化一个损失函数
- 梯度上升法：最大化一个效用函数

# 其他

欢迎大家关注我的个人公众号：是不是很酷



# Python 3 玩儿转机器学习

讲师：liuyubobobo

版权所有 侵权必究  
liuyubobobo