

Python 3 玩儿转机器学习

讲师：liuyubobobo

版权所有 侵权必究
liuyubobobo

主成分分析

Principal Component Analysis

慕课网《Python3机器学习》

讲师: liuyuboboo
版权所有, 侵权必究

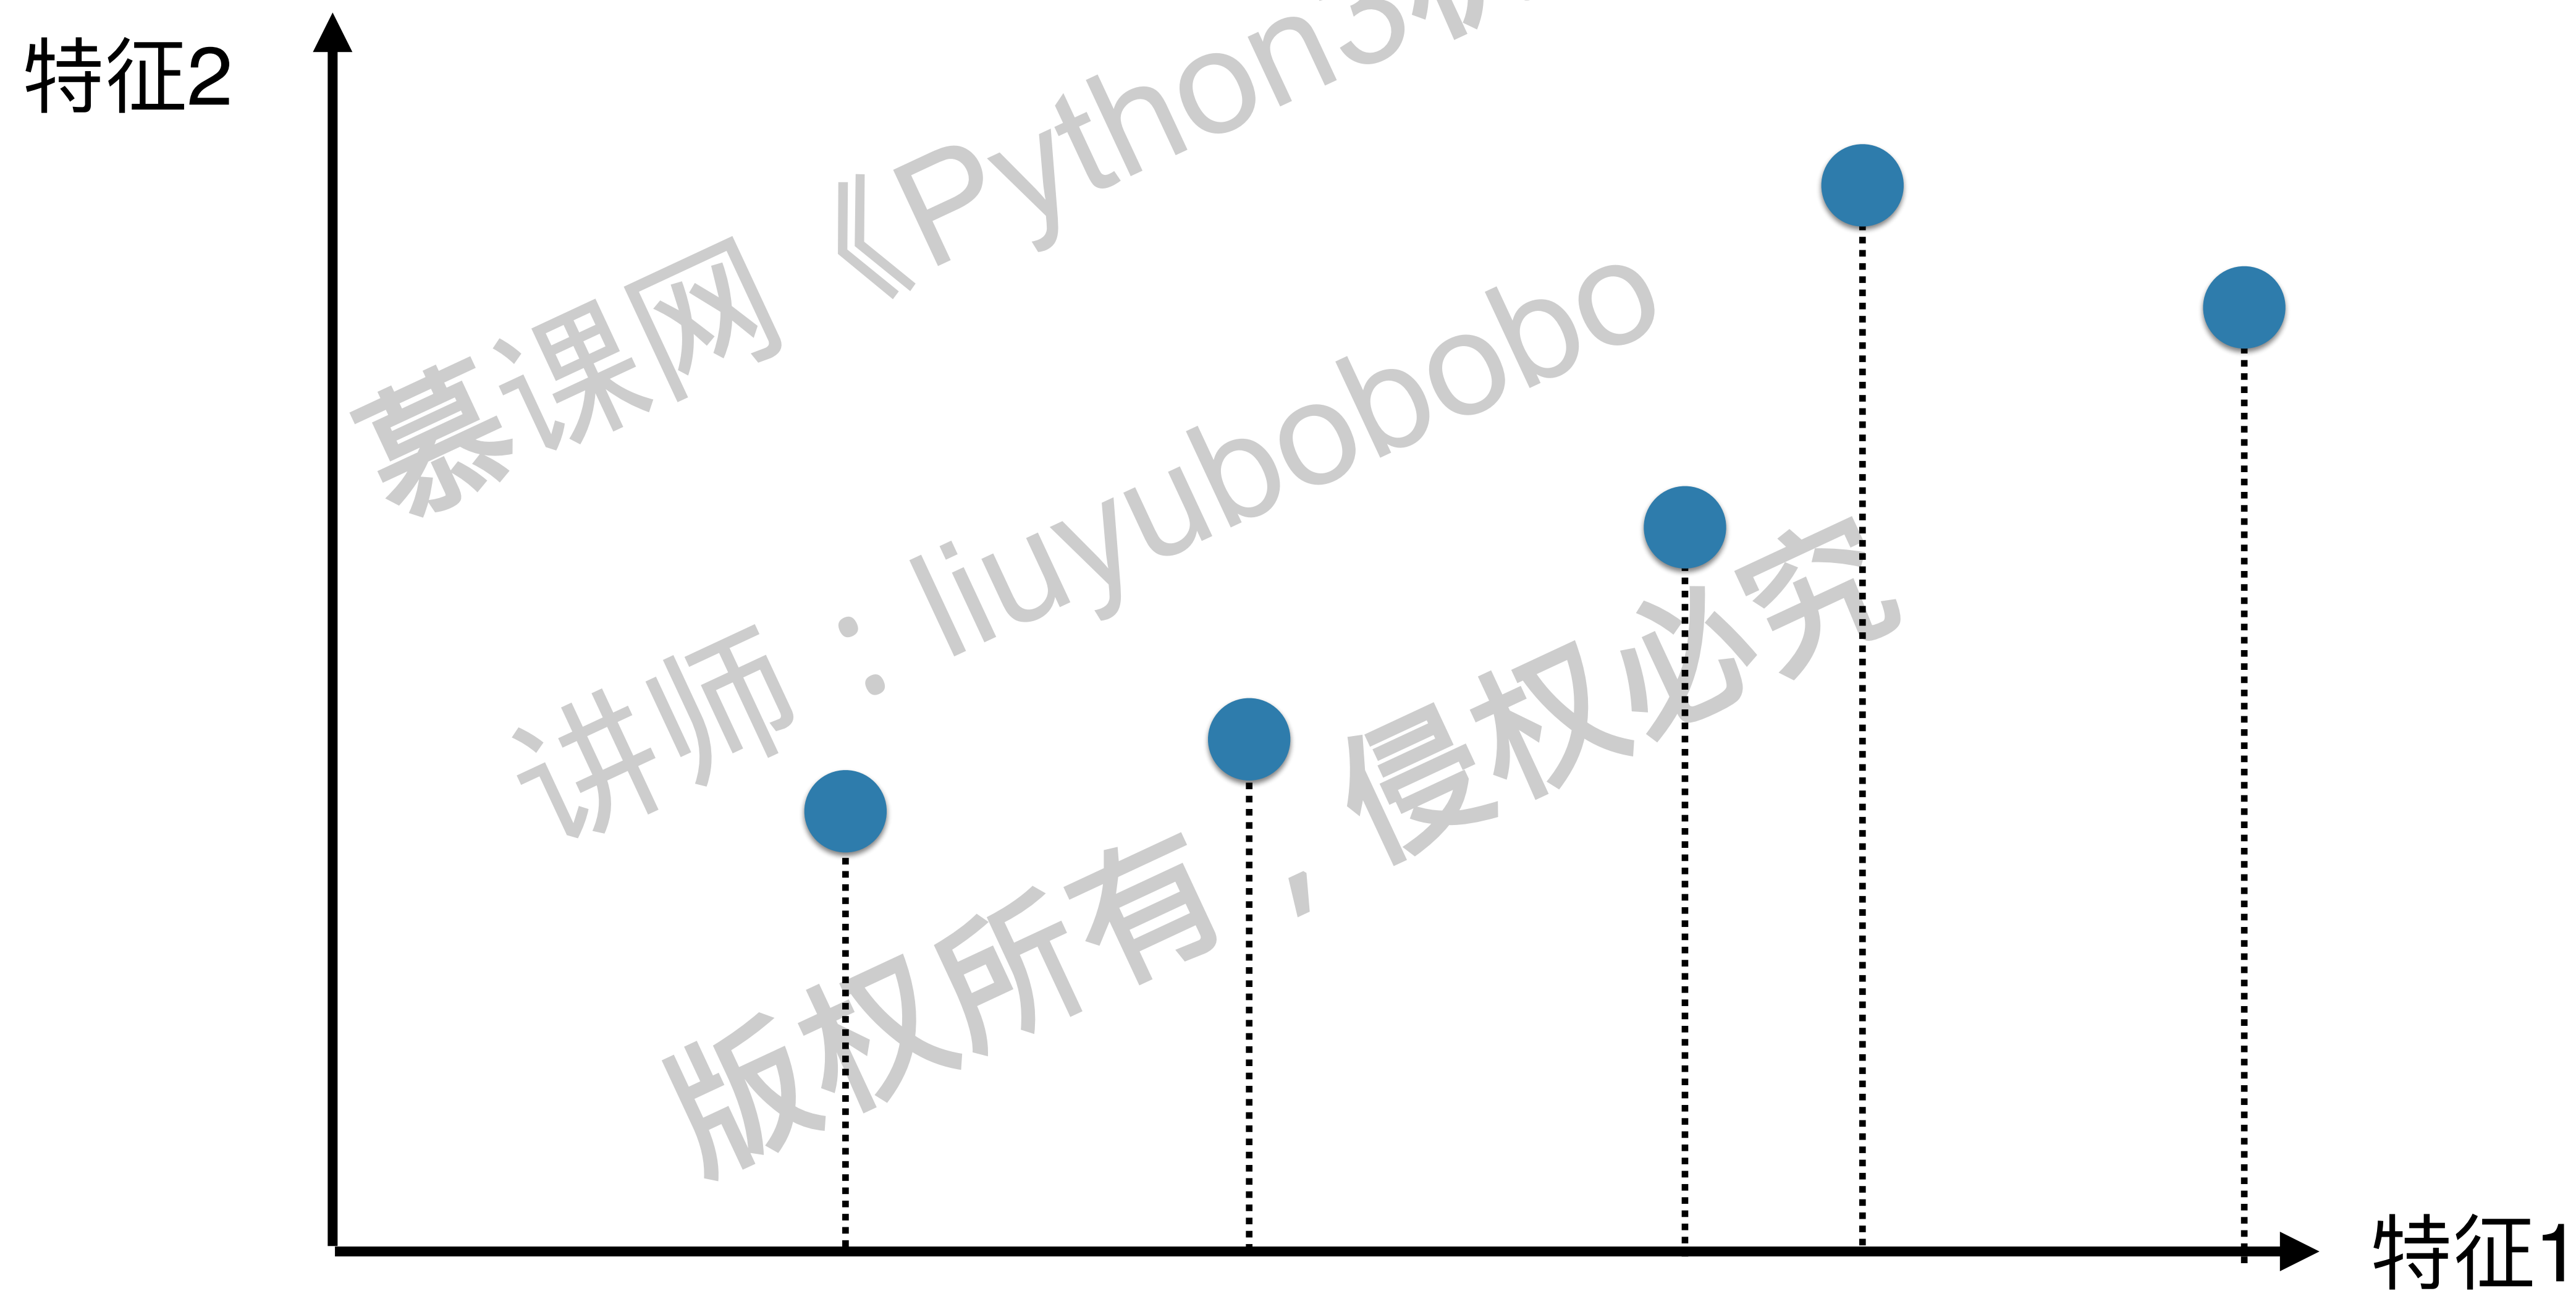
主成分分析

- 一个非监督的机器学习算法
- 主要用于数据的降维
- 通过降维，可以发现更便于人类理解的特征
- 其他应用：可视化；去噪

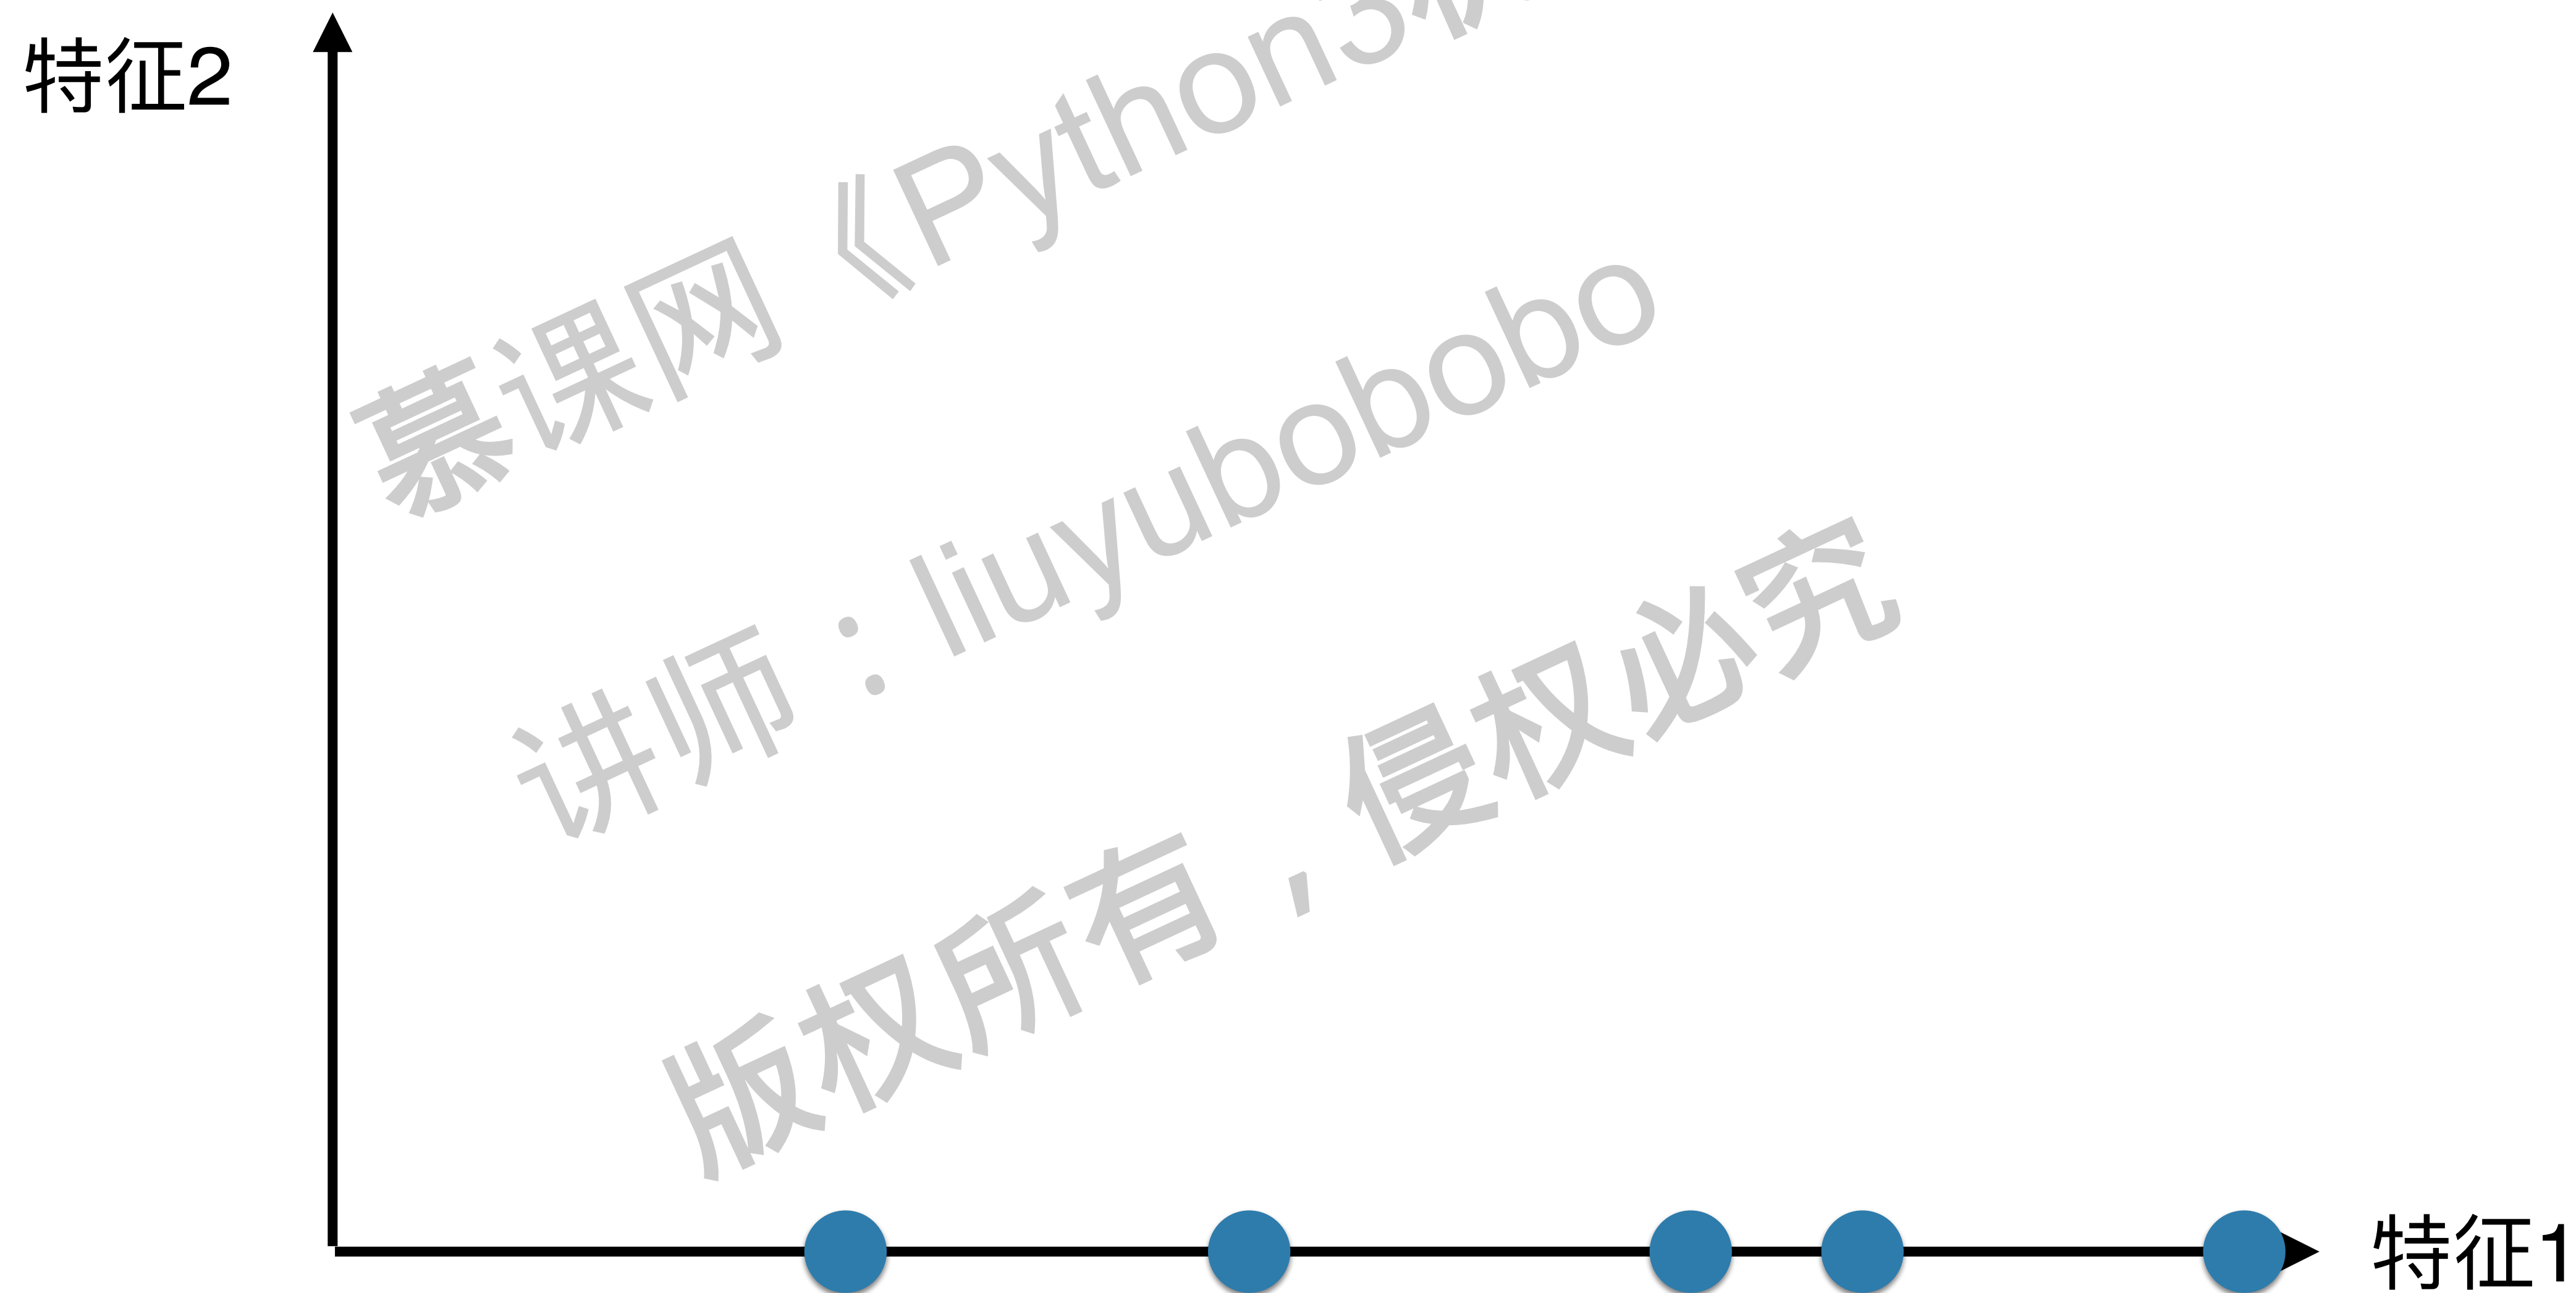
主成分分析



主成分分析




主成分分析



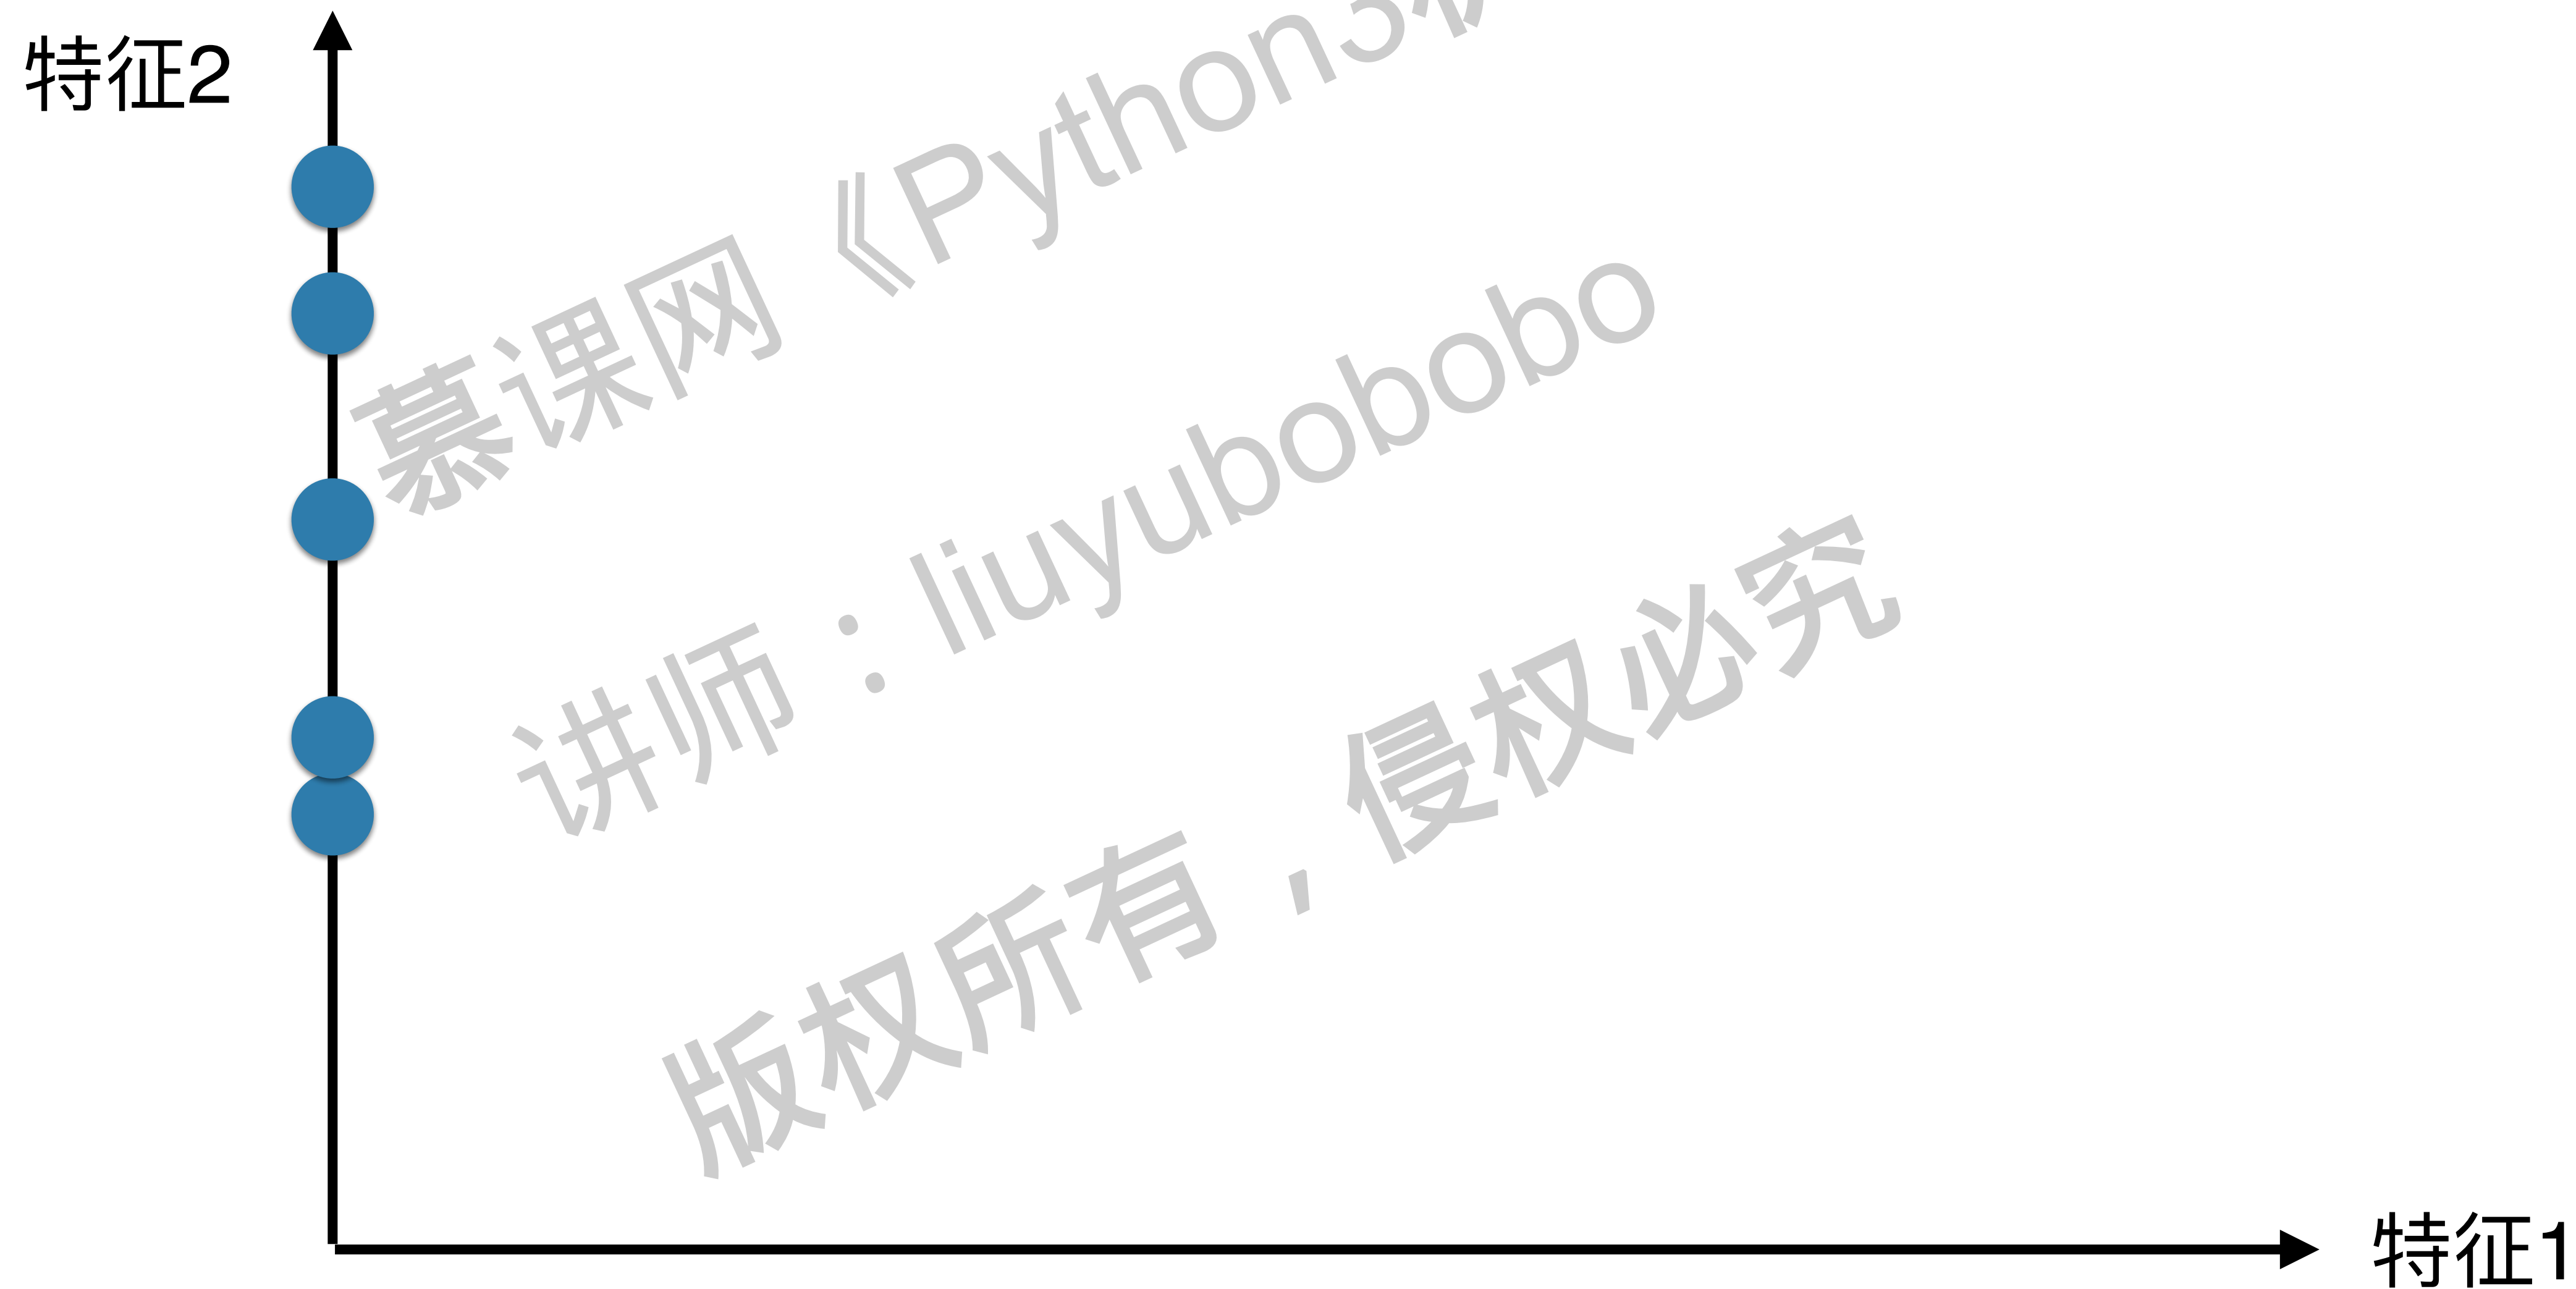
主成分分析




主成分分析



主成分分析

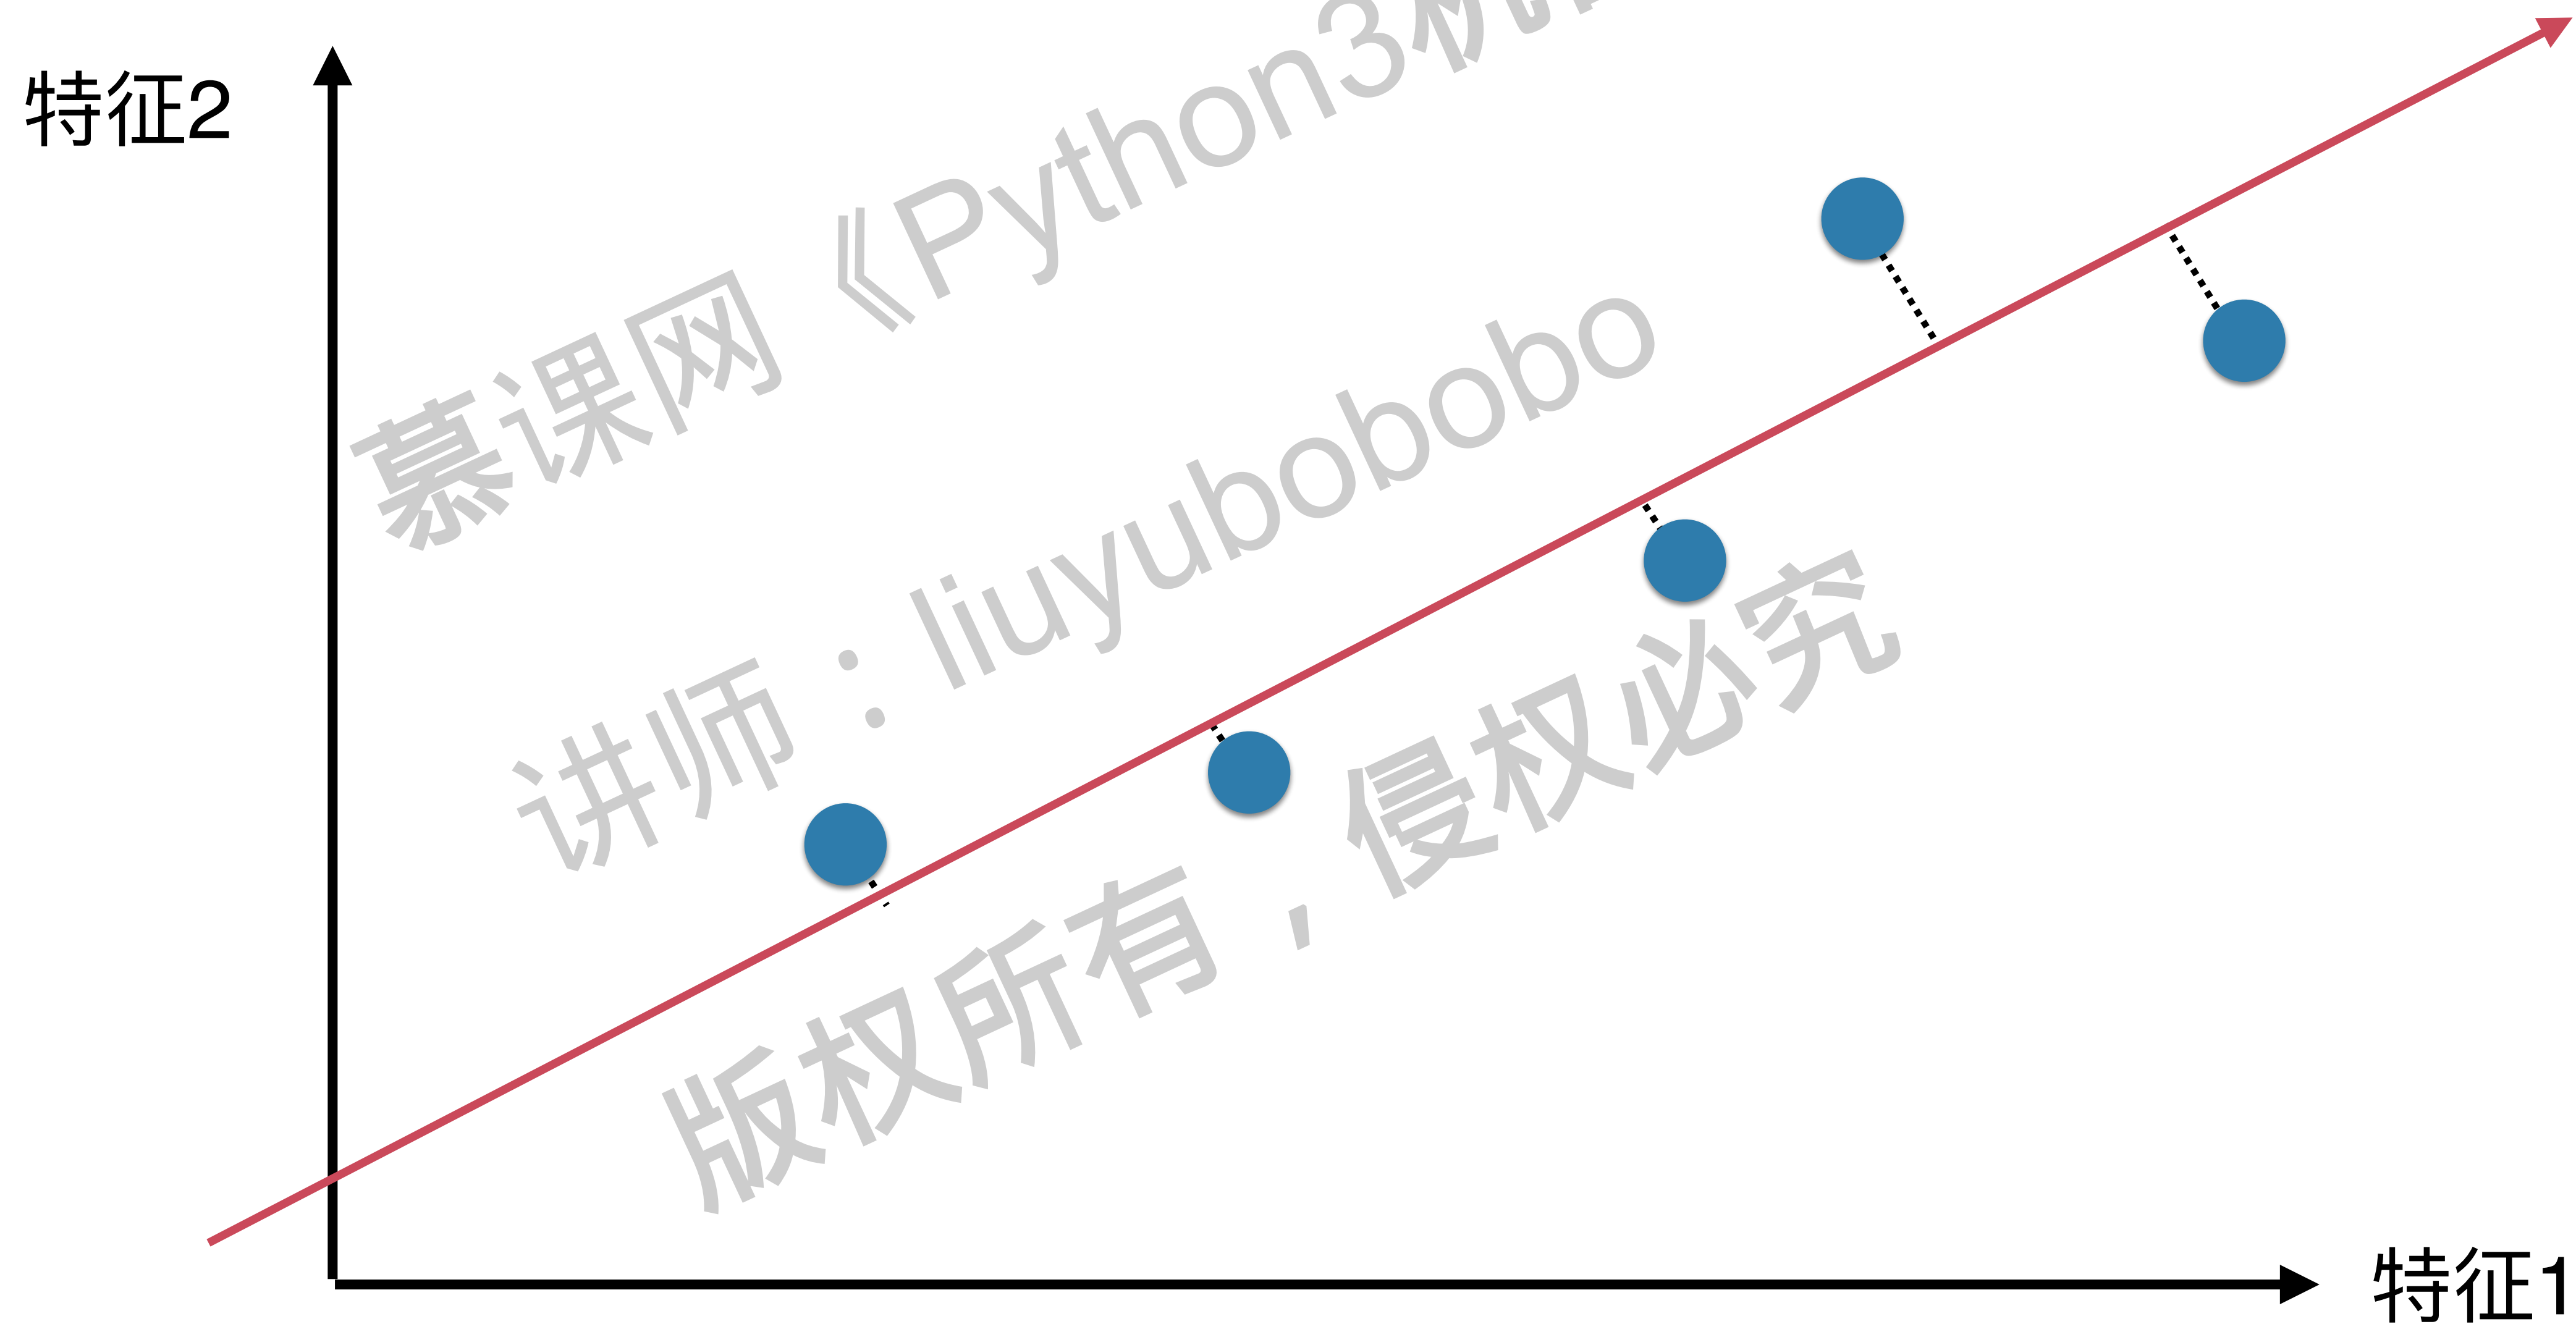


主成分分析



这是最好的方案吗？

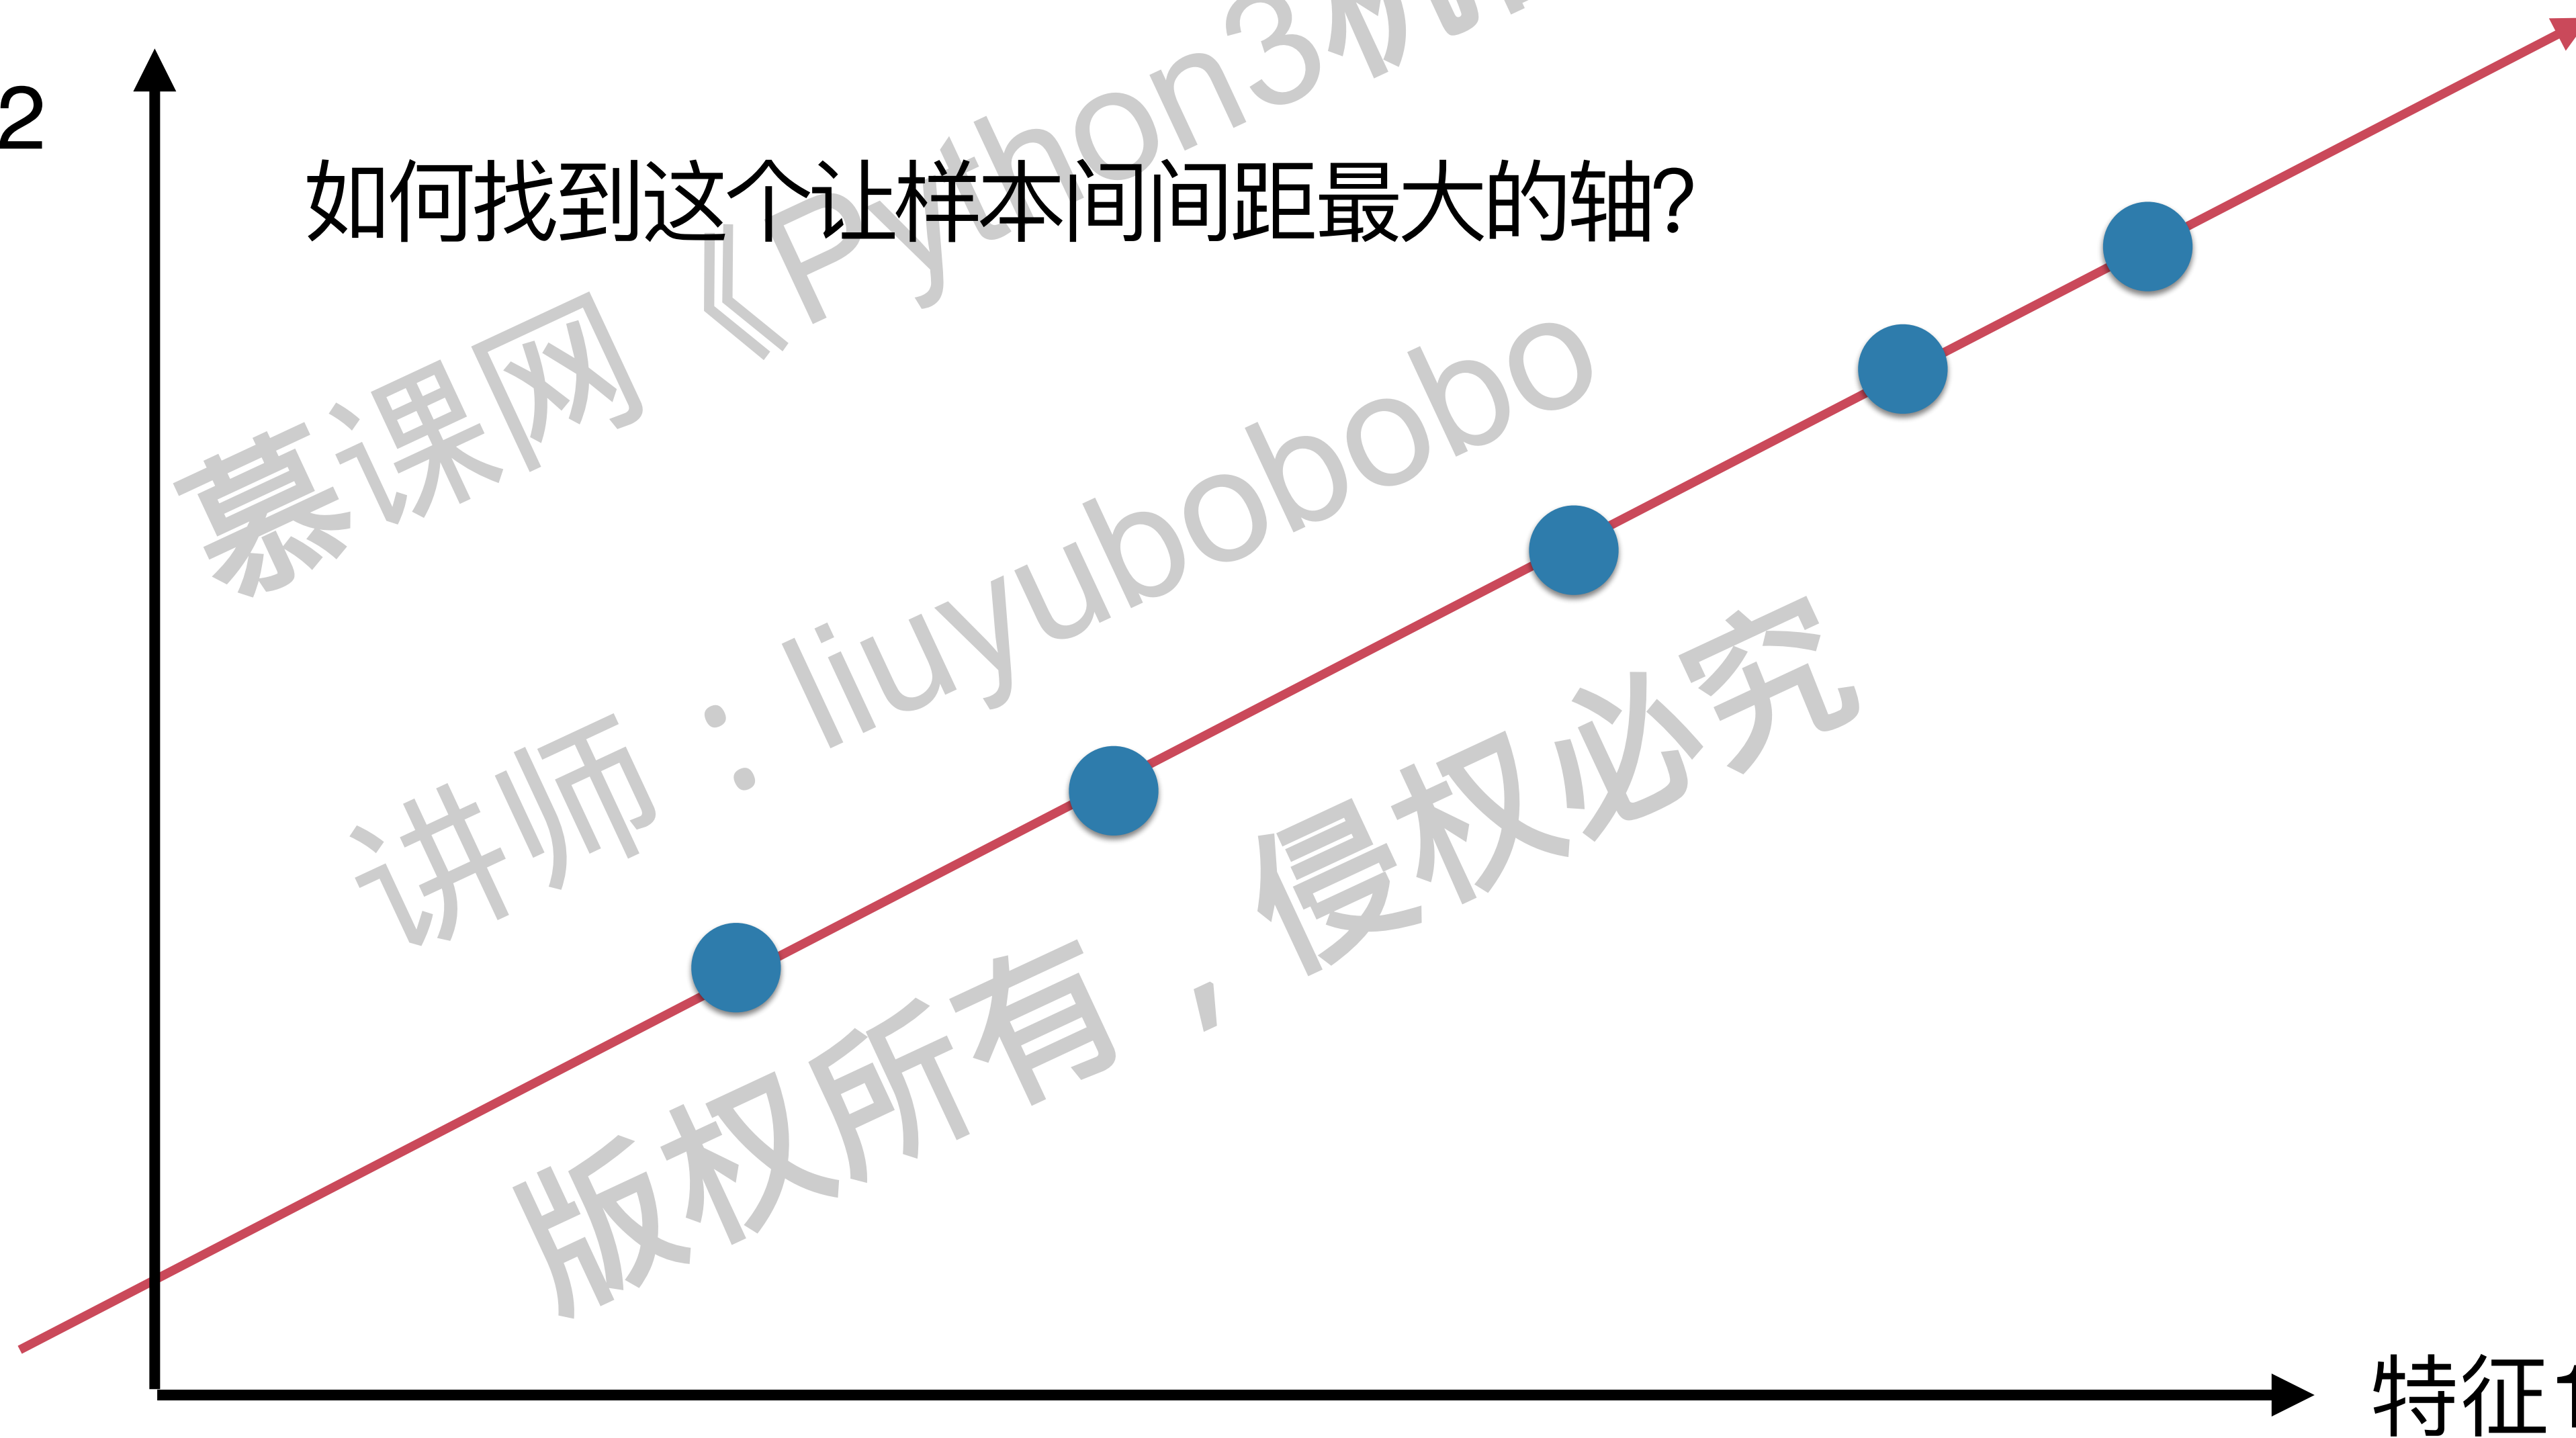
主成分分析



主成分分析

特征2

如何找到这个让样本间间距最大的轴?



特征1

主成分分析

如何找到这个让样本间间距最大的轴？

如何定义样本间间距？


使用方差 (Variance)

$$Var(x) = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x})^2$$

主成分分析

特征2

找到一个轴，使得样本空间的所有点映射到这个轴后，方差最大

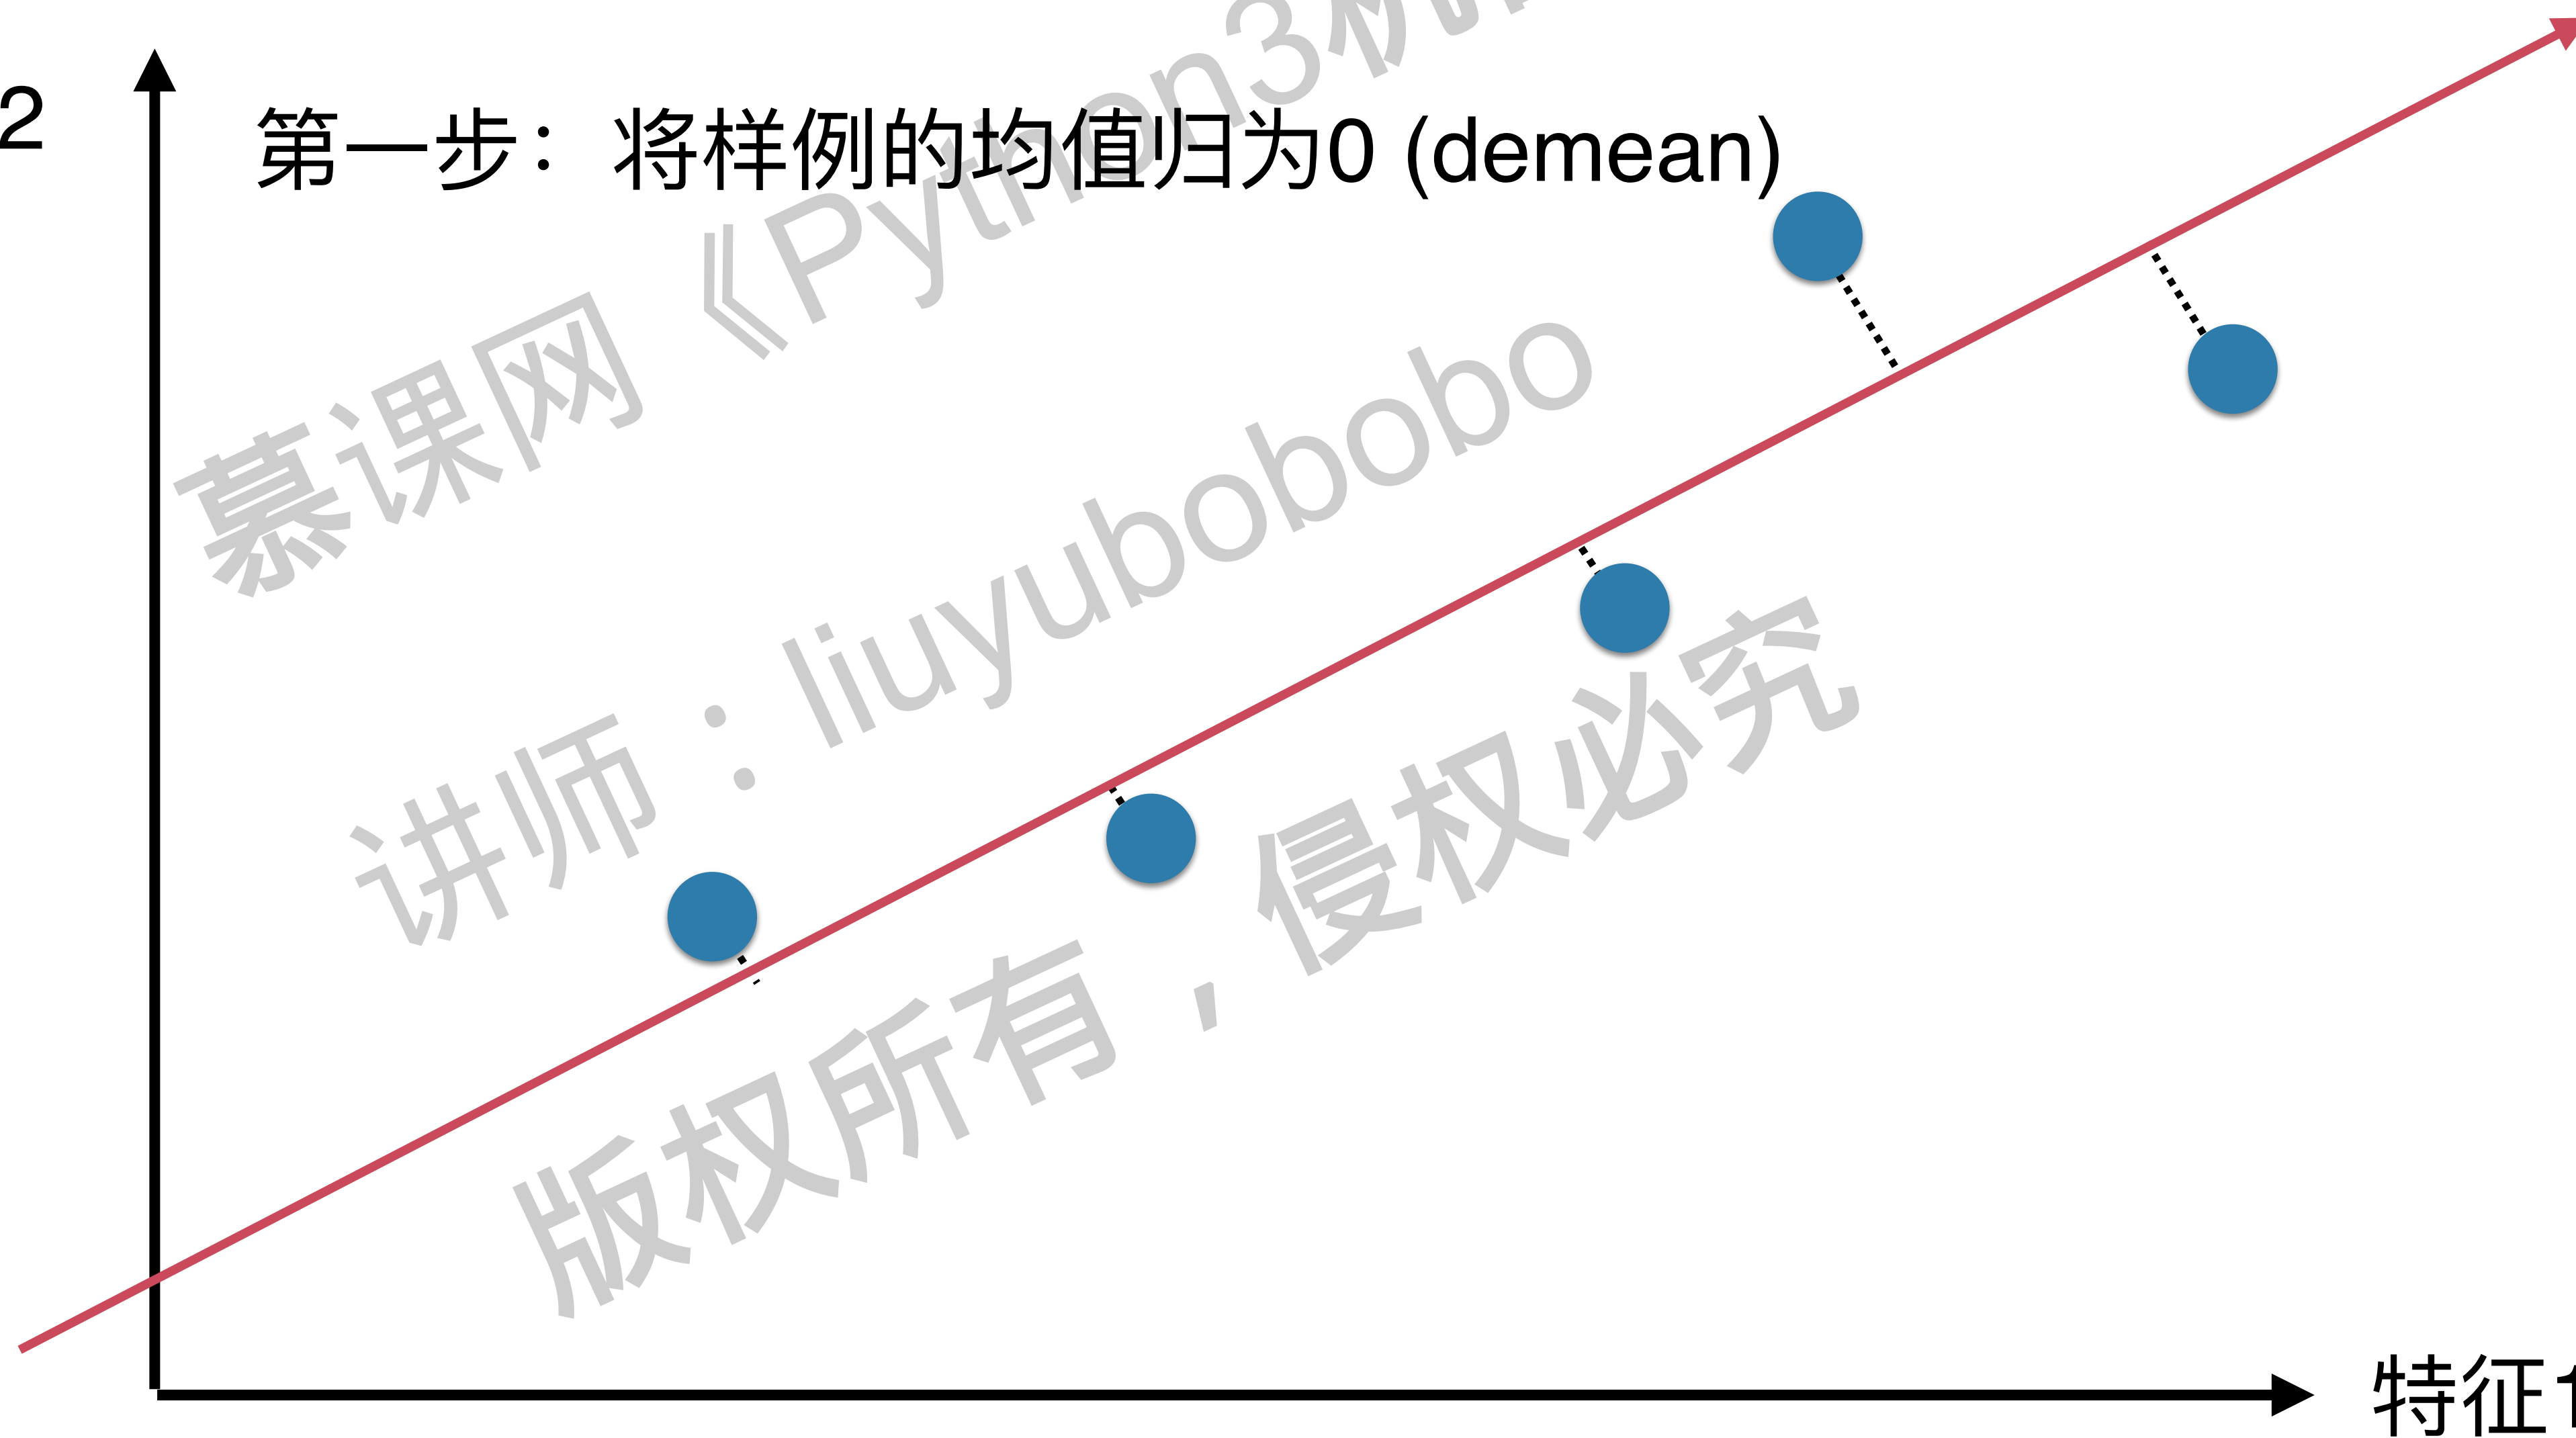


特征1


主成分分析

特征2


第一步：将样例的均值归为0 (demean)



主成分分析



主成分分析



主成分分析

对所有的样本进行demean处理

我们要求一个轴的方向 $w = (w1, w2)$

使得我们所有的样本，映射到w以后，有：

$$Var(X_{project}) = \frac{1}{m} \sum_{i=1}^m (X_{project}^{(i)} - \bar{X}_{project})^2 \quad \text{最大}$$

主成分分析

对所有的样本进行demean处理

我们要求一个轴的方向 $w = (w1, w2)$

使得我们所有的样本，映射到w以后，有：

$$Var(X_{project}) = \frac{1}{m} \sum_{i=1}^m \left\| X_{project}^{(i)} - \bar{X}_{project} \right\|^2 \quad \text{最大}$$

主成分分析

对所有的样本进行demean处理


我们要求一个轴的方向 $w = (w1, w2)$

使得我们所有的样本，映射到w以后，有：

$$Var(X_{project}) = \frac{1}{m} \sum_{i=1}^m \|X_{project}^{(i)}\|^2 \quad \text{最大}$$

主成分分析

$$Var(X_{project}) = \frac{1}{m} \sum_{i=1}^m \|X_{project}^{(i)}\|^2 \quad \text{最大}$$



$$(X_{pr1}^{(i)}, X_{pr2}^{(i)})$$

$$w = (w_1, w_2)$$

$$X^{(i)} \cdot w = \|X^{(i)}\| \cdot \|w\| \cdot \cos \theta$$


$$X^{(i)} \cdot w = \|X^{(i)}\| \cdot \cos \theta$$

$$X^{(i)} \cdot w = \|X_{project}^{(i)}\|$$

$$X^{(i)} = (X_1^{(i)}, X_2^{(i)})$$

主成分分析

$$Var(X_{project}) = \frac{1}{m} \sum_{i=1}^m \|X^{(i)} \cdot w\|^2 \quad \text{最大}$$



$$w = (w_1, w_2)$$

$$X^{(i)} \cdot w = \|X^{(i)}\| \cdot \|w\| \cdot \cos \theta$$

$$X^{(i)} \cdot w = \|X^{(i)}\| \cdot \cos \theta$$

$$X^{(i)} \cdot w = \|X_{project}^{(i)}\|$$

$$X^{(i)} = (X_1^{(i)}, X_2^{(i)})$$

主成分分析

目标：求 w ，使得 $Var(X_{project}) = \frac{1}{m} \sum_{i=1}^m (X^{(i)} \cdot w)^2$ 最大

$$Var(X_{project}) = \frac{1}{m} \sum_{i=1}^m (X_1^{(i)} w_1 + X_2^{(i)} w_2 + \dots + X_n^{(i)} w_n)^2$$

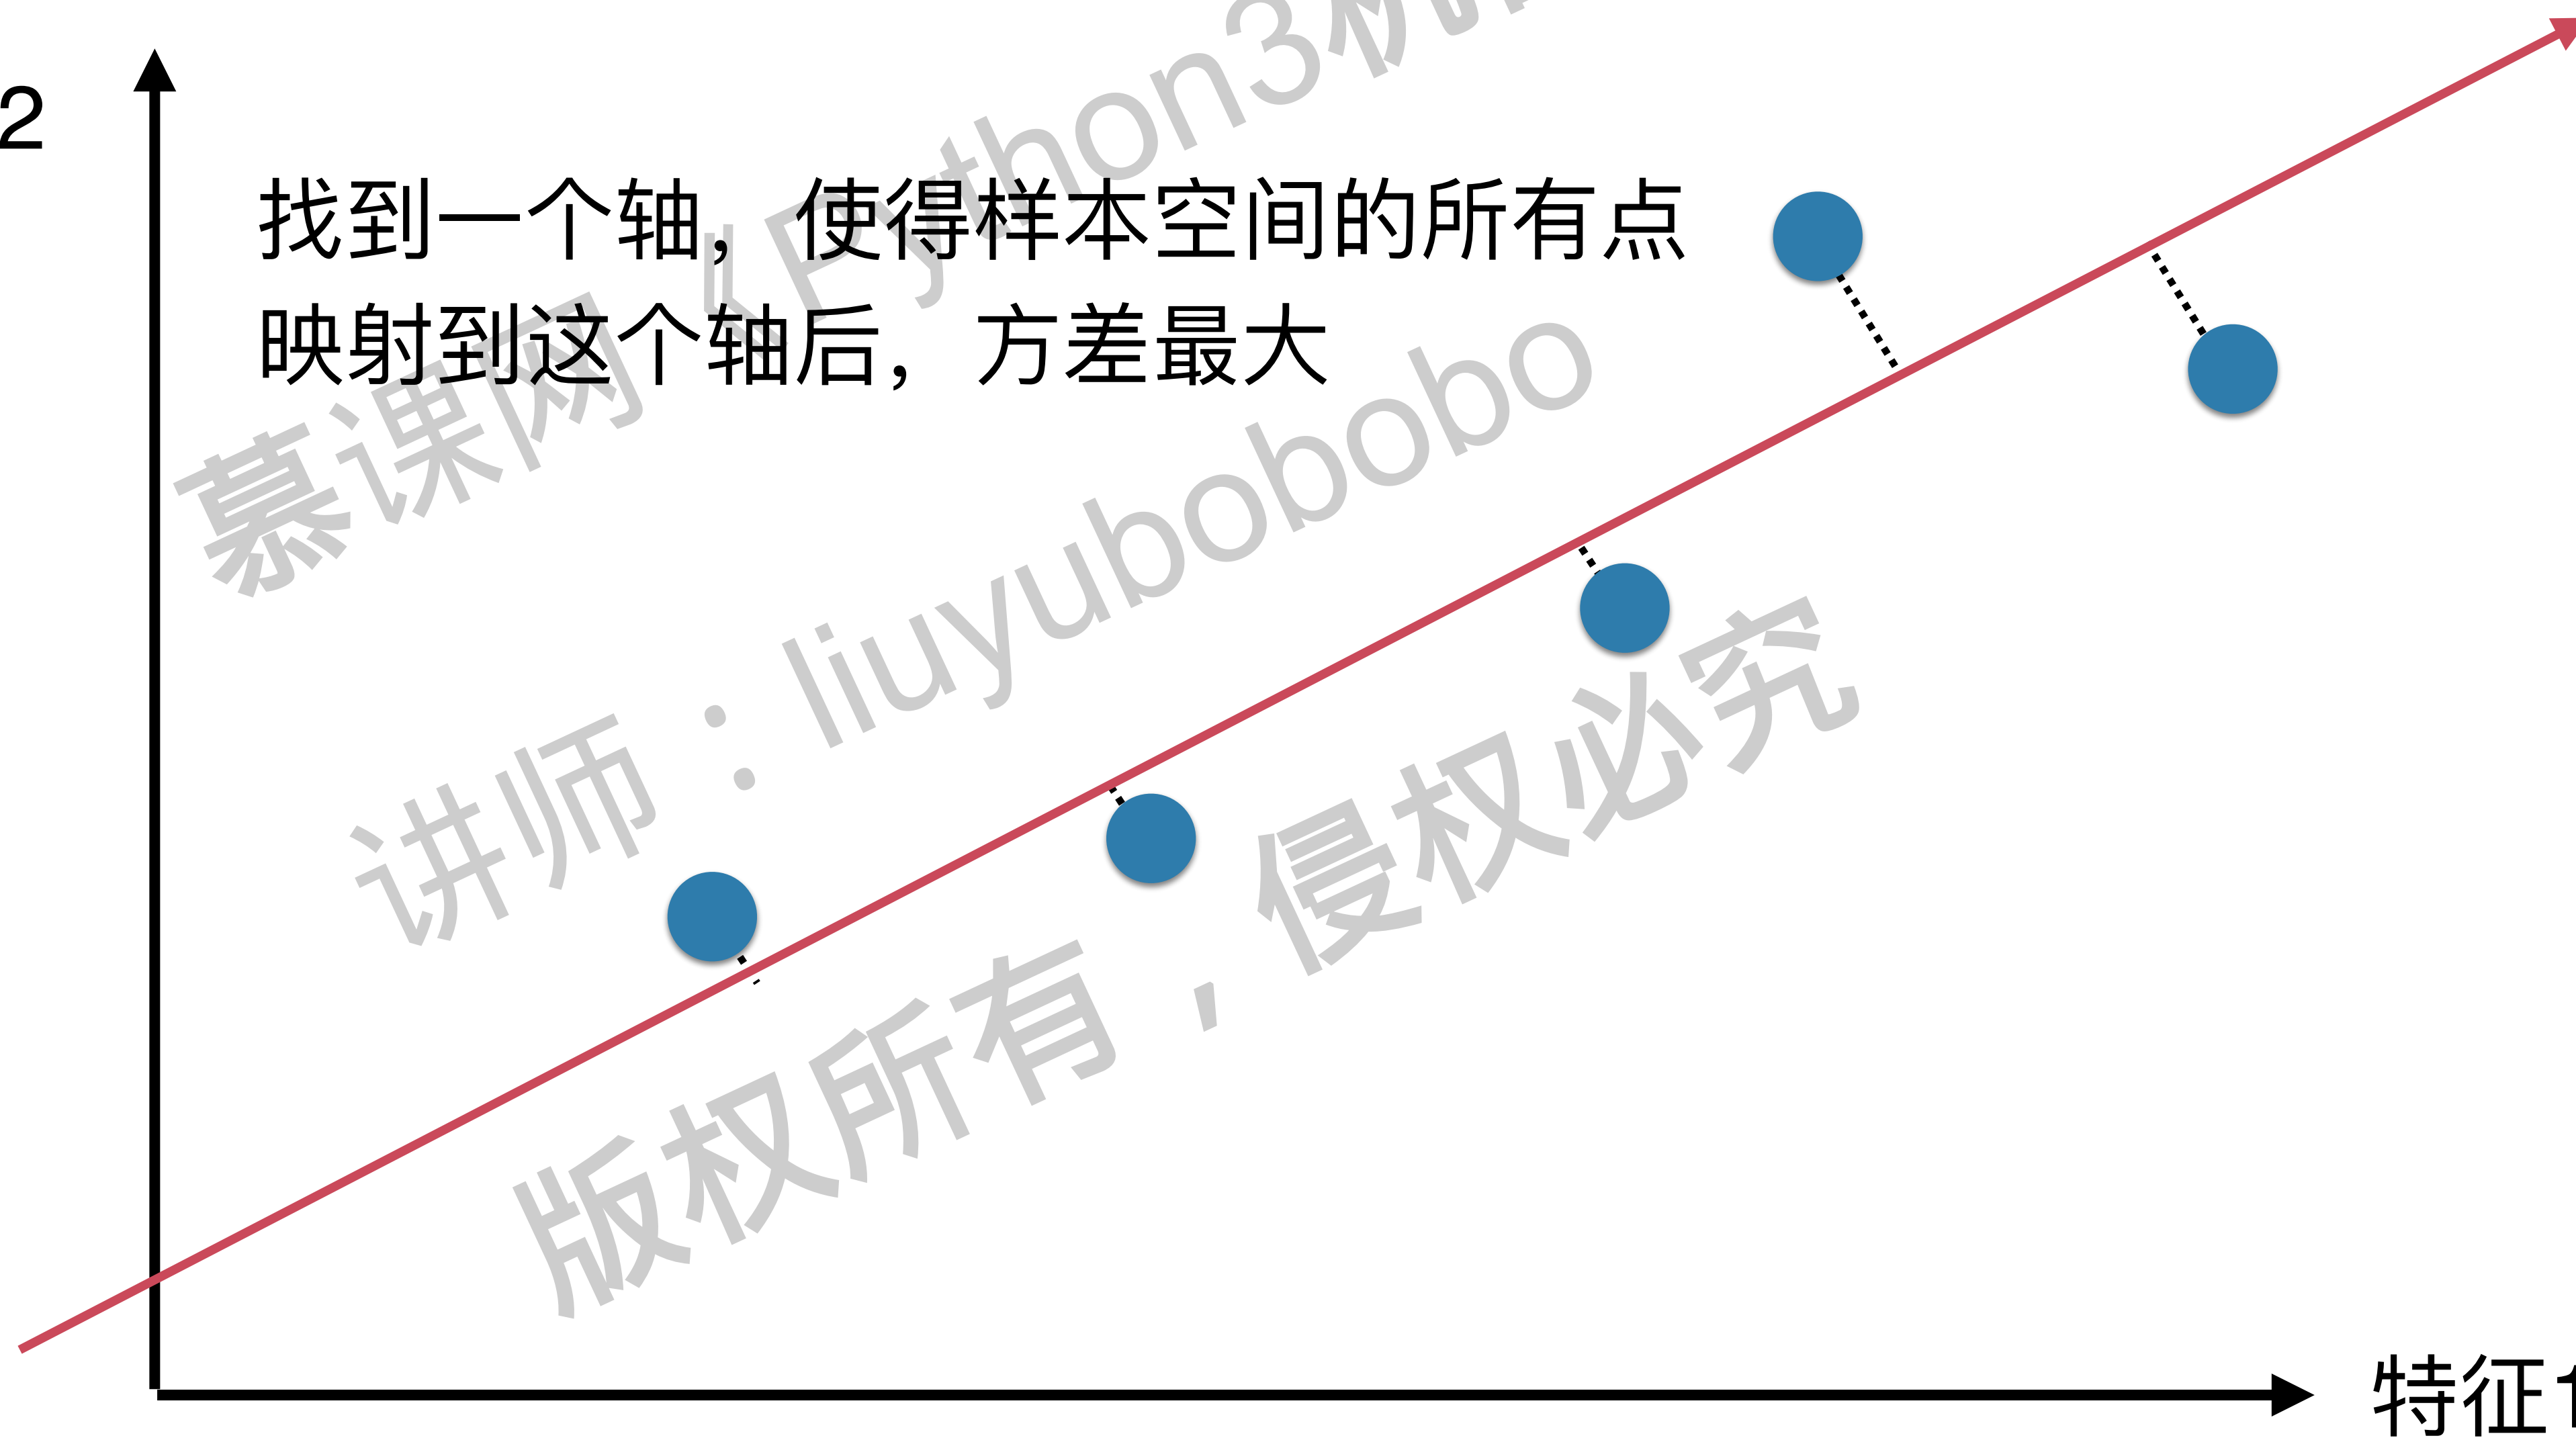
$$Var(X_{project}) = \frac{1}{m} \sum_{i=1}^m \left(\sum_{j=1}^n X_j^{(i)} w_j \right)^2$$

一个目标函数的最优化问题，使用梯度上升法解决

主成分分析

特征2

找到一个轴，使得样本空间的所有点映射到这个轴后，方差最大



特征1

线性回归

输出标记

使预测结果的MSE尽量小



特征

梯度上升法解决主成分分析问题

讲师：liuyuboboo
版权所有，侵权必究

主成分分析

目标：求 w ，使得 $f(X) = \frac{1}{m} \sum_{i=1}^m (X_1^{(i)}w_1 + X_2^{(i)}w_2 + \dots + X_n^{(i)}w_n)^2$ 最大

$$\nabla f = \begin{pmatrix} \frac{\partial f}{\partial w_1} \\ \frac{\partial f}{\partial w_2} \\ \dots \\ \frac{\partial f}{\partial w_n} \end{pmatrix} = \frac{2}{m} \begin{pmatrix} \sum_{i=1}^m (X_1^{(i)}w_1 + X_2^{(i)}w_2 + \dots + X_n^{(i)}w_n)X_1^{(i)} \\ \sum_{i=1}^m (X_1^{(i)}w_1 + X_2^{(i)}w_2 + \dots + X_n^{(i)}w_n)X_2^{(i)} \\ \dots \\ \sum_{i=1}^m (X_1^{(i)}w_1 + X_2^{(i)}w_2 + \dots + X_n^{(i)}w_n)X_n^{(i)} \end{pmatrix}$$

主成分分析

目标：求 w ，使得 $f(X) = \frac{1}{m} \sum_{i=1}^m (X_1^{(i)}w_1 + X_2^{(i)}w_2 + \dots + X_n^{(i)}w_n)^2$ 最大

$$\nabla f = \begin{pmatrix} \frac{\partial f}{\partial w_1} \\ \frac{\partial f}{\partial w_2} \\ \dots \\ \frac{\partial f}{\partial w_n} \end{pmatrix} = \frac{2}{m} \begin{pmatrix} \sum_{i=1}^m (X^{(i)}w)X_1^{(i)} \\ \sum_{i=1}^m (X^{(i)}w)X_2^{(i)} \\ \dots \\ \sum_{i=1}^m (X^{(i)}w)X_n^{(i)} \end{pmatrix}$$

主成分分析

$$\begin{aligned}
 &= \frac{2}{m} \begin{pmatrix} \sum_{i=1}^m (X^{(i)} w) X_1^{(i)} \\ \sum_{i=1}^m (X^{(i)} w) X_2^{(i)} \\ \dots \\ \sum_{i=1}^m (X^{(i)} w) X_n^{(i)} \end{pmatrix} \\
 &\quad \cdot \begin{pmatrix} X_1^{(1)} & X_2^{(1)} & X_3^{(1)} & \dots & X_n^{(1)} \\ X_1^{(2)} & X_2^{(2)} & X_3^{(2)} & \dots & X_n^{(2)} \\ X_1^{(3)} & X_2^{(3)} & X_3^{(3)} & \dots & X_n^{(3)} \\ \dots & \dots & \dots & \dots & \dots \\ X_1^{(m)} & X_2^{(m)} & X_3^{(m)} & \dots & X_n^{(m)} \end{pmatrix} \\
 &= \frac{2}{m} \cdot (X w)^T \cdot X \\
 &= \frac{2}{m} \cdot X^T (X w)
 \end{aligned}$$

主成分分析

$$\nabla f = \frac{2}{m} \begin{pmatrix} \sum_{i=1}^m (X^{(i)} w) X_1^{(i)} \\ \sum_{i=1}^m (X^{(i)} w) X_2^{(i)} \\ \dots \\ \sum_{i=1}^m (X^{(i)} w) X_n^{(i)} \end{pmatrix} = \frac{2}{m} \cdot X^T (Xw)$$

实践：基于BGGA实现PCA

讲师：liuyubob666

版权所有，侵权必究

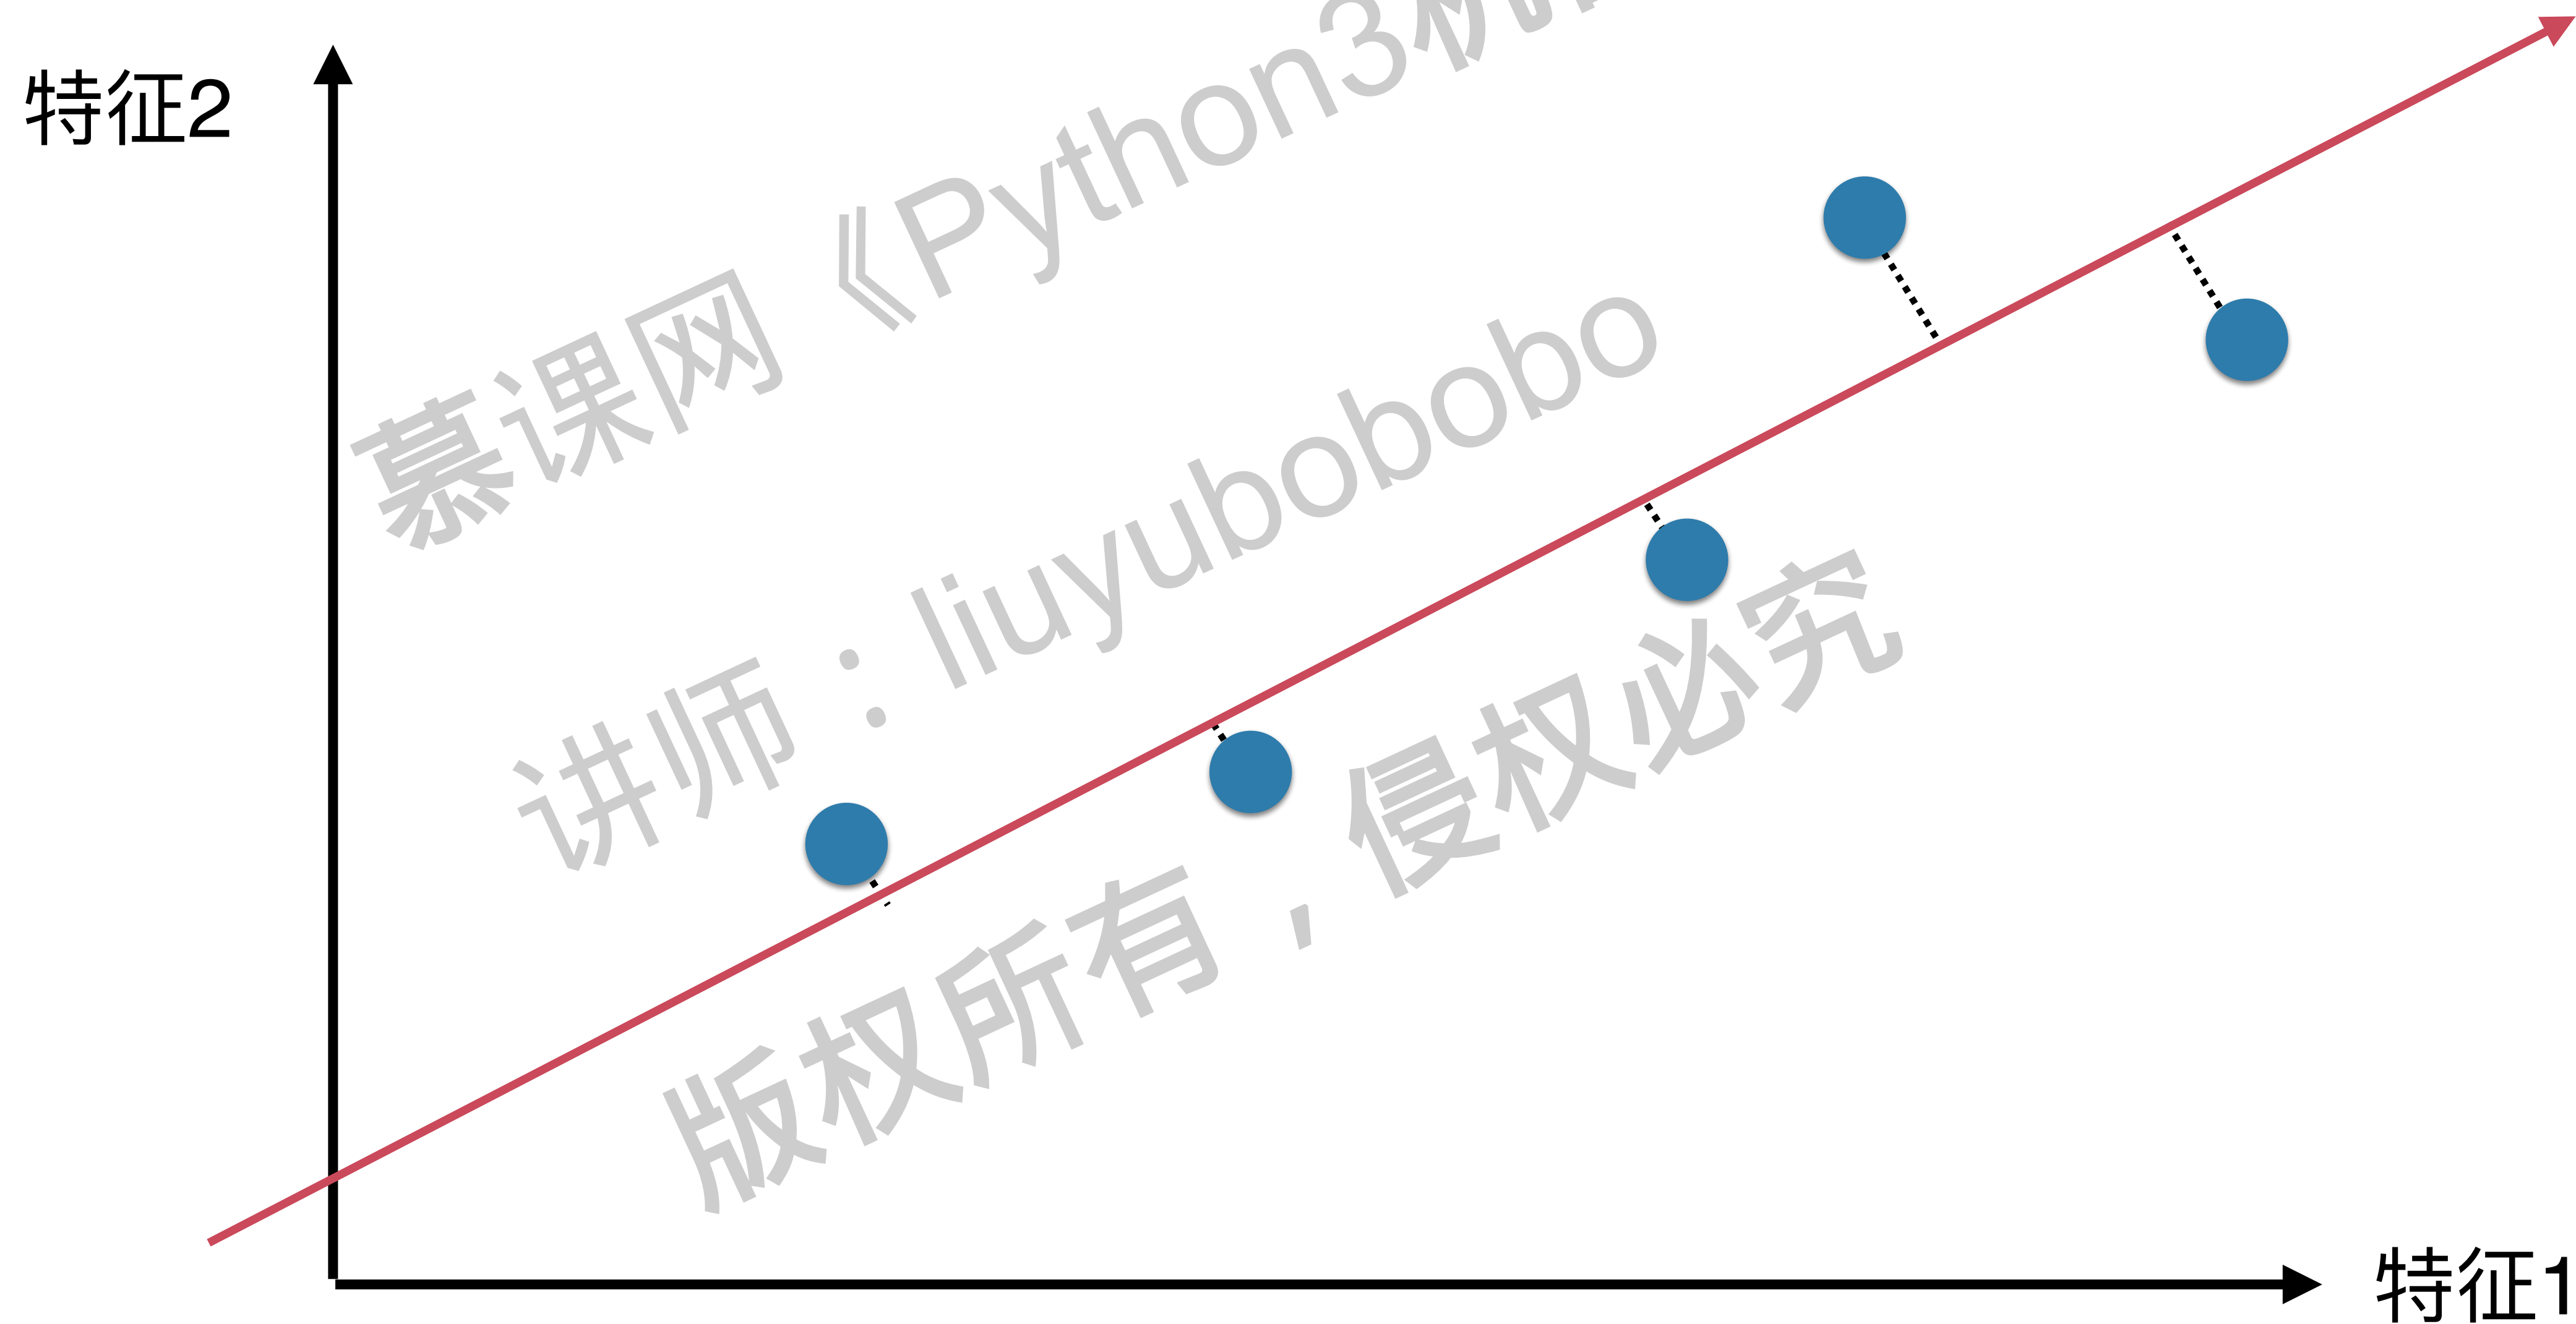
慕课网《Python3机器学习》

求数据的前n个主成分

讲师：liuyuboboo

版权所有，侵权必究

主成分分析



主成分分析




主成分分析

求出第一主成分以后，如何求出下一个主成分？

数据进行改变，将数据在第一个主成分上的分量去掉

主成分分析

数据进行改变，将数据在第一个主成分上的分量去掉



$$X^{(i)} \cdot w = \|X_{project}^{(i)}\|$$

$$X_{project}^{(i)} = \|X_{project}^{(i)}\| \cdot w$$

$$X'^{(i)} = X^{(i)} - X_{project}^{(i)}$$

主成分分析

求出第一主成分以后，如何求出下一个主成分？

数据进行改变，将数据在第一个主成分上的分量去掉

在新的数据上求第一主成分

慕课网《Python3机器学习》

实践：求前 n 个主成分

讲师：liuyuboboo

版权所有，侵权必究

高维数据向低维数据映射

讲师：liuyuboboo

版权所有，侵权必究

高维数据向低维数据映射

$$X = \begin{pmatrix} X_1^{(1)} & X_2^{(1)} & \dots & X_n^{(1)} \\ X_1^{(2)} & X_2^{(2)} & \dots & X_n^{(2)} \\ \dots & \dots & \dots & \dots \\ X_1^{(m)} & X_2^{(m)} & \dots & X_n^{(m)} \end{pmatrix} \quad W_k = \begin{pmatrix} W_1^{(1)} & W_2^{(1)} & \dots & W_n^{(1)} \\ W_1^{(2)} & W_2^{(2)} & \dots & W_n^{(2)} \\ \dots & \dots & \dots & \dots \\ W_1^{(k)} & W_2^{(k)} & \dots & W_n^{(k)} \end{pmatrix}$$

$$X \cdot W_k^T = X_k$$

$$\begin{matrix} m*n & n*k & m*k \end{matrix}$$

高维数据向低维数据映射

$$X_k = \begin{pmatrix} X_1^{(1)} & X_2^{(1)} & \dots & X_k^{(1)} \\ X_1^{(2)} & X_2^{(2)} & \dots & X_k^{(2)} \\ \dots & \dots & \dots & \dots \\ X_1^{(m)} & X_2^{(m)} & \dots & X_k^{(m)} \end{pmatrix} \quad W_k = \begin{pmatrix} W_1^{(1)} & W_2^{(1)} & \dots & W_n^{(1)} \\ W_1^{(2)} & W_2^{(2)} & \dots & W_n^{(2)} \\ \dots & \dots & \dots & \dots \\ W_1^{(k)} & W_2^{(k)} & \dots & W_n^{(k)} \end{pmatrix}$$

$$X_k \cdot W_k = X_m$$

$$\begin{matrix} m \times k & k \times n & m \times n \end{matrix}$$

慕课网《Python3机器学习》

实践：封装PCA

讲师：liuyuboboo

版权所有，侵权必究

慕课网《Python3机器学习》

scikit-learn中的PCA

讲师：liuyuboboo

版权所有，侵权必究

慕课网《Python3机器学习》

MNIST数据集

讲师：liuyuboboy

版权所有，侵权必究


慕课网《Python3机器学习》

使用PCA进行去噪

讲师：liuyuboboo

版权所有，侵权必究

主成分分析



主成分分析



实践：使用PCA进行去噪

讲师：liuyuboboo

版权所有，侵权必究

慕课网《Python3机器学习》

特征脸

讲师：liuyuboboo

版权所有，侵权必究

高维数据向低维数据映射

$$X = \begin{pmatrix} X_1^{(1)} & X_2^{(1)} & \dots & X_n^{(1)} \\ X_1^{(2)} & X_2^{(2)} & \dots & X_n^{(2)} \\ \dots & \dots & \dots & \dots \\ X_1^{(m)} & X_2^{(m)} & \dots & X_n^{(m)} \end{pmatrix} \quad W_k = \begin{pmatrix} W_1^{(1)} & W_2^{(1)} & \dots & W_n^{(1)} \\ W_1^{(2)} & W_2^{(2)} & \dots & W_n^{(2)} \\ \dots & \dots & \dots & \dots \\ W_1^{(k)} & W_2^{(k)} & \dots & W_n^{(k)} \end{pmatrix}$$

$$X \cdot W_k^T = X_k$$

其他

欢迎大家关注我的个人公众号：是不是很酷



Python 3 玩儿转机器学习

讲师：liuyubobobo

版权所有 侵权必究
liuyubobobo